

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN – TIN

ĐỒ ÁN TỐT NGHIỆP

Xây dựng ứng dụng hỗ trợ tư vấn bất động sản tích hợp Chatbot

TRẦN TRUNG HIẾU

Email: hieu.tt227114@sis.hust.edu.vn

Mã sinh viên: 20227114

Chuyên ngành Toán - Tin

Giảng viên hướng dẫn:

TS. Trần Anh Tú

Chữ ký của GVHD

HÀ NỘI, 6/2026

ĐẠI HỌC BÁCH KHOA HÀ NỘI
KHOA TOÁN – TIN

ĐỒ ÁN TỐT NGHIỆP

Xây dựng ứng dụng hỗ trợ tư vấn bất động sản tích hợp Chatbot

TRẦN TRUNG HIẾU

Email: hieu.tt227114@sis.hust.edu.vn

Mã sinh viên: 20227114

Chuyên ngành Toán - Tin

Giảng viên hướng dẫn:

TS. Trần Anh Tú

Chữ ký của GVHD

HÀ NỘI, 6/2026

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

Biểu mẫu của Đề tài/khóa luận tốt nghiệp theo qui định của viện, tuy nhiên cần đảm bảo giáo viên giao đề tài ký và ghi rõ họ và tên.

Trường hợp có 2 giáo viên hướng dẫn thì sẽ cùng ký tên.

Hà Nội, ngày tháng ...
năm ...

Giáo viên hướng dẫn

Ký và ghi rõ họ tên

PHIẾU BÁO CÁO TIẾN ĐỘ ĐỒ ÁN

- Phiếu này in từ hệ thống số hóa

Lời cảm ơn

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc đến TS. Trần Anh Tú, người đã tận tình hướng dẫn, định hướng và động viên em trong suốt quá trình thực hiện đồ án tốt nghiệp này. Những góp ý quý báu của thầy về kiến trúc hệ thống, phương pháp nghiên cứu và cách trình bày đã giúp em hoàn thiện đồ án một cách tốt nhất.

Em cũng xin gửi lời cảm ơn đến các thầy cô trong Khoa Toán – Tin, Đại học Bách Khoa Hà Nội, những người đã trang bị cho em nền tảng kiến thức vững chắc về công nghệ thông tin, trí tuệ nhân tạo và kỹ năng nghiên cứu trong suốt những năm học vừa qua.

Cuối cùng, em xin cảm ơn gia đình và bạn bè đã luôn ủng hộ, tạo điều kiện thuận lợi và là nguồn động viên tinh thần to lớn để em có thể tập trung hoàn thành đồ án này.

Tóm tắt nội dung đồ án

Đồ án này trình bày quá trình phân tích, thiết kế và xây dựng một nền tảng tư vấn bất động sản thông minh tích hợp chatbot đa tác tử sử dụng kỹ thuật tạo sinh tăng cường truy xuất. Hệ thống hướng đến thị trường bất động sản Việt Nam, cung cấp cho người dùng khả năng tìm kiếm nhà đất, phân tích thị trường, tư vấn pháp lý và đầu tư thông qua giao diện hội thoại tự nhiên bằng tiếng Việt.

Về phương pháp thực hiện, đồ án áp dụng kiến trúc dịch vụ vi mô với máy chủ FastAPI, giao diện Next.js, cơ sở dữ liệu PostgreSQL tích hợp tìm kiếm véc-tơ cho tìm kiếm ngữ nghĩa, và khung công tác LangGraph để điều phối đa tác tử. Hệ thống sử dụng mô hình BGE-M3 (1024 chiều) cho véc-tơ đặc trưng tiếng Việt, Google Gemini 2.0 Flash cho phân loại ý định và sinh phản hồi, cùng mô hình xếp hạng lại đa ngôn ngữ để xếp hạng kết quả truy xuất. Dữ liệu được thu thập từ batdongsan.com.vn qua đường ống xử lý dữ liệu tự động hóa bằng Apache Airflow.

Kết quả đạt được là một hệ thống hoàn chỉnh với các chức năng: duyệt và lọc danh sách bất động sản, xem chi tiết và bản đồ, thống kê thị trường, và đặc biệt là chatbot đa tác tử có khả năng xử lý đồng thời nhiều loại truy vấn (tìm kiếm, phân tích thị trường, tư vấn pháp lý, tư vấn đầu tư) với nguồn trích dẫn rõ ràng. Hệ thống có tính thực tế cao, có thể triển khai làm nền tảng dịch vụ bất động sản hoặc phát triển mở rộng theo hướng tích hợp thêm nguồn dữ liệu, cải thiện chất lượng véc-tơ đặc trưng và bổ sung tác tử chuyên biệt.

Qua đồ án, em đã đạt được kiến thức và kỹ năng về thiết kế hệ thống toàn diện, xây dựng đường ống dữ liệu, tích hợp cơ sở dữ liệu véc-tơ cho tìm kiếm ngữ nghĩa, phát triển hệ thống đa tác tử với LangGraph, và triển khai ứng dụng với Docker.

Hà Nội, ngày tháng ...
năm...

Sinh viên thực hiện

Ký và ghi rõ họ tên

Mục lục

GIỚI THIỆU	12
Đặt vấn đề	12
Mục tiêu của đề tài	13
Phạm vi nghiên cứu	14
Phương pháp tiếp cận	15
Đóng góp của đồ án	16
Bố cục của báo cáo	17
1 CƠ SỞ LÝ THUYẾT	18
1.1 Tổng quan về lĩnh vực nghiên cứu	18
1.1.1 Nền tảng bất động sản trực tuyến	18
1.1.2 Chatbot và trợ lý ảo trong bất động sản	19
1.2 Các khái niệm cơ bản	19
1.2.1 Kỹ thuật tạo sinh tăng cường truy xuất	19
1.2.2 Hệ đa tác tử	20
1.2.3 Véc-tơ đặc trưng và Tìm kiếm ngữ nghĩa	22
1.2.4 Tìm kiếm lai và Xếp hạng lại	23
1.3 Các công nghệ sử dụng	25
1.3.1 FastAPI	25
1.3.2 Next.js	25
1.3.3 PostgreSQL + pgvector	26
1.3.4 LangGraph	26
1.3.5 Google Gemini	27
1.3.6 BGE-M3 Embedding	27
1.3.7 Cohere Rerank	28
1.3.8 Redis	28
1.3.9 Apache Airflow	29
1.3.10 Playwright	29
1.3.11 Các thư viện và công cụ khác	30
2 PHÂN TÍCH THIẾT KẾ HỆ THỐNG	31
2.1 Phân tích yêu cầu	31
2.1.1 Yêu cầu chức năng	31

2.1.2	Yêu cầu phi chức năng	36
2.2	Thiết kế kiến trúc hệ thống	38
2.2.1	Kiến trúc tổng thể	38
2.3	Thiết kế cơ sở dữ liệu	45
2.3.1	Mô hình quan hệ	45
2.3.2	Chiến lược indexing	46
2.4	Thiết kế giao diện người dùng	47
3	TRIỂN KHAI VÀ KIỂM THỬ	48
3.1	Triển khai hệ thống với Docker	48
3.1.1	Kiến trúc triển khai	48
3.1.2	Cấu hình Docker Compose	48
3.1.3	Cấu hình chi tiết từng dịch vụ	49
3.1.4	Mạng nội bộ và giao tiếp giữa các dịch vụ	52
3.1.5	Quy trình triển khai	52
3.1.6	Nạp dữ liệu ban đầu	55
3.2	Kiểm thử hệ thống	55
3.2.1	Chiến lược kiểm thử	55
3.2.2	Công cụ và khung công tác kiểm thử	56
	KẾT LUẬN	57
	Kết quả đạt được	57
	Hạn chế	58
	Hướng phát triển	59
	PHỤ LỤC	60
	CHỈ MỤC	72
	TÀI LIỆU THAM KHẢO	73

Danh sách hình vẽ

2.1	Kiến trúc tổng thể hệ thống Nền tảng Tư vấn Bất động sản Tích hợp Chatbot	39
3.1	Kiến trúc triển khai Docker Compose	48
3.2	Sơ đồ kiến trúc tổng thể hệ thống (5 tầng: Người dùng – Frontend – Backend & Agent Service – Data – Pipeline)	65

Danh sách bảng

2.1	Các yêu cầu phi chức năng của hệ thống	38
3.1	Danh sách API endpoints chính của hệ thống (tiền tố mặc định: <code>/api/v1</code>)	69

DANH MỤC KÝ HIỆU VÀ TỪ VIẾT TẮT

Ký hiệu / Từ viết tắt	Diễn giải
AI	Artificial Intelligence – Trí tuệ nhân tạo
API	Application Programming Interface
BGE-M3	BAAI General Embedding – Multilingual, Multi-functionality, Multi-granularity
CORS	Cross-Origin Resource Sharing
CSV	Comma-Separated Values
DAG	Directed Acyclic Graph
ETL	Extract, Transform, Load
HNSW	Hierarchical Navigable Small World (thuật toán index vector)
JWT	JSON Web Token
kNN	k-Nearest Neighbors
LLM	Large Language Model – Mô hình ngôn ngữ lớn
ORM	Object-Relational Mapping
RAG	Retrieval-Augmented Generation
ROI	Return on Investment
SQL	Structured Query Language
SSE	Server-Sent Events
SSR	Server-Side Rendering
VND	Việt Nam Đồng

GIỚI THIỆU

Đặt vấn đề

Thị trường bất động sản Việt Nam những năm gần đây chứng kiến sự phát triển sôi động với hàng trăm nghìn giao dịch mỗi năm và nhu cầu thông tin ngày càng cao từ phía người mua, người bán cũng như nhà đầu tư. Các cổng thông tin bất động sản trực tuyến như batdongsan.com.vn, alonhadat.com.vn đã trở thành kênh tiếp cận chính, với hàng chục nghìn tin đăng mới mỗi ngày. Tuy nhiên, việc khai thác thông tin từ các nền tảng này một cách hiệu quả vẫn còn nhiều thách thức.

Thách thức đầu tiên là tình trạng thông tin phân mảnh và quá tải. Dữ liệu bất động sản nằm rải rác trên nhiều nền tảng với hàng chục nghìn tin đăng. Người dùng phải tự duyệt qua hàng trăm kết quả, so sánh thủ công giữa các tin để tìm được bất động sản phù hợp. Việc tổng hợp thông tin từ nhiều nguồn và đưa ra quyết định dựa trên dữ liệu là một quá trình tốn nhiều thời gian và công sức.

Thách thức thứ hai là sự thiếu hụt tư vấn chuyên sâu đa lĩnh vực. Một giao dịch bất động sản không chỉ đơn thuần là tìm kiếm và so sánh giá. Người mua cần được tư vấn về tình trạng pháp lý (sổ đỏ, quy hoạch, thủ tục sang tên), xu hướng thị trường (biến động giá, khu vực tiềm năng) và tiềm năng đầu tư (khả năng sinh lời, thanh khoản, tỷ suất cho thuê). Tuy nhiên, các nền tảng hiện tại chủ yếu chỉ hiển thị danh sách tin đăng và bộ lọc cơ bản, chưa có khả năng tư vấn tổng hợp đa chiều.

Thách thức thứ ba là rào cản ngôn ngữ trong tìm kiếm ngữ nghĩa. Các giải pháp tìm kiếm truyền thống dựa trên khớp từ khóa chính xác không hiểu được ngữ nghĩa và ngữ cảnh của truy vấn tiếng Việt. Ví dụ, người dùng tìm “căn hộ thoáng mát gần công viên, dưới 3 tỷ” yêu cầu hệ thống phải hiểu được khái niệm “thoáng mát”, “gần công viên” – những khái niệm không thể tra cứu bằng câu lệnh truy vấn thông thường.

Thách thức thứ tư là thiếu tự động hóa trong thu thập và xử lý dữ liệu. Quy trình thu thập dữ liệu bất động sản thường thủ công, không theo kịp tốc độ cập nhật của thị trường. Dữ liệu thô từ các nền tảng cần được làm sạch (chuẩn hóa giá, diện tích, địa chỉ), làm giàu (gán tọa độ địa lý, phân loại ý định) và cập nhật định kỳ mới có thể sử dụng được cho các hệ thống tìm kiếm thông minh.

Thách thức cuối cùng là thiếu công cụ phân tích thị trường trực quan. Người dùng phổ thông và nhà đầu tư thiếu các công cụ giúp họ nắm bắt bức tranh tổng quan về thị trường như giá trung bình theo khu vực, phân bố loại hình bất động sản, xu hướng biến động giá. Các số liệu thống kê thường nằm trong các báo cáo định kỳ, không có sẵn dưới dạng tương

tác trực tuyến.

Trước bối cảnh đó, việc xây dựng một nền tảng bất động sản thông minh, tích hợp trợ lý ảo có khả năng hiểu ngôn ngữ tự nhiên tiếng Việt và tư vấn đa lĩnh vực (từ tìm kiếm bất động sản, phân tích thị trường, tư vấn pháp lý đến đánh giá đầu tư) là một nhu cầu cấp thiết. Hệ thống cần được xây dựng trên nền tảng dữ liệu được thu thập và cập nhật tự động, đảm bảo thông tin luôn mới và đáng tin cậy.

Mục tiêu của đề tài

Đề án hướng đến việc xây dựng một hệ thống toàn diện giải quyết các thách thức nêu trên, với năm mục tiêu chính.

Mục tiêu thứ nhất: Xây dựng nền tảng web bất động sản hoàn chỉnh với giao diện người dùng hiện đại, sử dụng công nghệ kết xuất phía máy chủ cho hiệu năng cao và tối ưu hóa cho công cụ tìm kiếm. Nền tảng bao gồm: trang duyệt danh sách nhà đất bán và cho thuê với phân trang và sắp xếp đa tiêu chí (giá, diện tích, ngày đăng); bộ lọc nâng cao theo loại tin, loại hình bất động sản, thành phố, quận/huyện, khoảng giá, diện tích, số phòng ngủ, số phòng tắm, hướng nhà và từ khóa; trang chi tiết bất động sản với đầy đủ thông số kỹ thuật (giá, diện tích, pháp lý, nội thất, hướng, mặt tiền, số tầng, tọa độ); bảng thống kê thị trường trực quan với các chỉ số tổng quan và biểu đồ phân tích; hệ thống xác thực người dùng qua mã thông báo; và bảng điều khiển quản trị theo dõi trạng thái đường ống dữ liệu và vết xử lý của tác tử.

Mục tiêu thứ hai: Phát triển chatbot đa tác tử tích hợp kỹ thuật tạo sinh tăng cường truy xuất. Hệ thống bao gồm: đường ống chatbot nội bộ trong máy chủ với bộ định tuyến phân loại ý định (dựa trên từ khóa và dựa trên mô hình ngôn ngữ lớn) cùng bốn tác tử chuyên biệt đảm nhận các vai trò tìm kiếm bất động sản, phân tích thị trường, tư vấn pháp lý và tư vấn đầu tư; dịch vụ tác tử riêng biệt chạy đồ thị trạng thái với quy trình tám bước gồm xây dựng ngữ cảnh, kiểm tra trạng thái sẵn sàng, định tuyến, lập kế hoạch truy xuất, thực thi tác tử chuyên biệt song song, tổng hợp kết quả, kiểm tra an toàn và đề xuất ghi nhớ; hỗ trợ tiếng Việt toàn diện từ nhận diện ý định, trích xuất bộ lọc đến sinh phản hồi; cơ chế ghi nhớ người dùng cho phép chatbot cá nhân hóa phản hồi dựa trên lịch sử tương tác; và cơ chế đánh giá chất lượng cùng thu thập phản hồi người dùng.

Mục tiêu thứ ba: Xây dựng đường ống thu thập và xử lý dữ liệu tự động. Hệ thống thu thập dữ liệu sử dụng công cụ tự động hóa trình duyệt với cơ chế ẩn danh để lấy dữ liệu từ batdongsan.com.vn cho bốn loại nội dung: tin bán, tin cho thuê, dự án, tin tức. Đường ống xử lý bao gồm đầy đủ các bước: làm sạch (phân tích giá, diện tích, phân loại), làm giàu (mã hóa địa lý qua dịch vụ bản đồ, gán nhãn nhu cầu), chia đoạn ngữ nghĩa, tạo véc-tơ đặc

trung 1024 chiều bằng mô hình BGE-M3 và nạp vào cơ sở dữ liệu PostgreSQL tích hợp tìm kiếm véc-tơ qua các mô-đun chuyên biệt. Hệ thống còn có kho kiến thức pháp lý với khả năng xử lý tài liệu HTML và PDF. Toàn bộ được lập lịch tự động qua Apache Airflow với bốn luồng công việc: hàng ngày cho tin đăng, hàng tuần cho dự án và tin tức, hàng tháng cho kiến thức pháp lý.

Mục tiêu thứ tư: Triển khai hệ thống tìm kiếm lai hiệu quả, kết hợp tìm kiếm theo bộ lọc có cấu trúc với tìm kiếm ngữ nghĩa qua chỉ mục HNSW trên PostgreSQL. Hệ thống tích hợp xếp hạng lại qua mô hình chuyên dụng đa ngôn ngữ để cải thiện độ chính xác, bộ nhớ đệm Redis cho cả véc-tơ đặc trưng và kết quả tìm kiếm, cùng khả năng trích xuất bộ lọc tự động từ truy vấn tiếng Việt.

Mục tiêu thứ năm: Thiết kế kiến trúc dịch vụ vi mô có khả năng mở rộng với năm dịch vụ độc lập: PostgreSQL tích hợp tìm kiếm véc-tơ (cơ sở dữ liệu), Redis (bộ nhớ đệm), Backend API (máy chủ dịch vụ), Dịch vụ Tác tử (máy chủ dịch vụ với đồ thị trạng thái) và Frontend (giao diện người dùng). Hệ thống quan sát toàn diện bao gồm: theo dõi vết tác tử, các bước xử lý, lời gọi mô hình ngôn ngữ, sự kiện truy xuất; chỉ số giám sát; và phản hồi đánh giá chất lượng. Bộ kiểm thử hơn 55 tệp bao phủ toàn bộ các mô-đun.

Phạm vi nghiên cứu

Đồ án tập trung vào thị trường bất động sản Việt Nam. Dữ liệu được thu thập từ nguồn chính là batdongsan.com.vn – cổng thông tin bất động sản lớn nhất Việt Nam với hàng chục nghìn tin đăng mới mỗi ngày.

Về loại hình bất động sản, hệ thống bao gồm cả tin bán và cho thuê với các loại hình chính: căn hộ chung cư, nhà riêng, nhà mặt phố, đất nền, biệt thự, nhà phố thương mại.

Về chức năng, hệ thống phục vụ ba nhóm đối tượng. Đối với người dùng cuối: tìm kiếm và duyệt bất động sản với bộ lọc nâng cao; chatbot tư vấn đa lĩnh vực (tìm kiếm, thị trường, pháp lý, đầu tư); thống kê thị trường trực quan; xác thực và quản lý tài khoản. Đối với quản trị viên: giám sát đường ống dữ liệu qua bảng điều khiển; theo dõi vết xử lý của tác tử và hiệu năng hệ thống; quản lý phản hồi người dùng và đề xuất ghi nhớ. Đối với hệ thống: thu thập dữ liệu tự động theo lịch; xử lý toàn diện từ làm sạch đến tạo véc-tơ; tạo và lập chỉ mục véc-tơ đặc trưng; giám sát qua chỉ số hệ thống.

Về công nghệ, đồ án sử dụng: Next.js 16 + React 19 (TypeScript) với Bộ định tuyến ứng dụng và Tailwind CSS phiên bản 4 cho giao diện người dùng; FastAPI (Python 3.12), SQLAlchemy 2.0 bất đồng bộ và Pydantic phiên bản 2 cho máy chủ dịch vụ; FastAPI + LangGraph với đồ thị trạng thái tám nút và Google Gemini 2.0 Flash cho Dịch vụ Tác tử; PostgreSQL 16 + pgvector với chỉ mục HNSW cho cơ sở dữ liệu; Redis 7 cho bộ nhớ đệm;

Google Gemini 2.0 Flash cho mô hình ngôn ngữ và định tuyến, BGE-M3 cho véc-tơ đặc trưng 1024 chiều, mô hình Xếp hạng lại Đa ngôn ngữ cho xếp hạng; Apache Airflow cho lập lịch; công cụ tự động hóa trình duyệt cho thu thập dữ liệu; và dịch vụ mã hóa địa lý.

Về ngôn ngữ: giao diện người dùng và phản hồi chatbot sử dụng tiếng Việt; mã nguồn, chú thích, tên biến/hàm/lớp sử dụng tiếng Anh; đường dẫn thân thiện sử dụng tiếng Việt không dấu (/nha-dat-ban, /thi-truong, /dang-nhap).

Phương pháp tiếp cận

Đồ án được triển khai theo phương pháp phát triển mô-đun, kết hợp giữa xây dựng hạ tầng dữ liệu và phát triển ứng dụng.

Bước đầu tiên là thu thập và xử lý dữ liệu: xây dựng đường ống thu thập dữ liệu tự động từ batdongsan.com.vn. Dữ liệu thô được làm sạch, chuẩn hóa, làm giàu (mã hóa địa lý, gán nhãn nhu cầu) và tổ chức thành các bảng quan hệ trong PostgreSQL. Văn bản được chia thành các đoạn ngữ nghĩa và tạo véc-tơ đặc trưng bằng mô hình BGE-M3 để phục vụ tìm kiếm ngữ nghĩa.

Bước thứ hai là xây dựng máy chủ dịch vụ với FastAPI theo kiến trúc phân lớp rõ ràng: mô hình (ánh xạ cơ sở dữ liệu), lược đồ (kiểm tra dữ liệu), bộ định tuyến (điểm cuối API) và dịch vụ (logic nghiệp vụ). Các API cung cấp đầy đủ chức năng cho giao diện người dùng: truy vấn danh sách bất động sản với bộ lọc và sắp xếp, thống kê thị trường, xác thực người dùng, và quan trọng nhất – tích hợp chatbot đa tác tử.

Bước thứ ba là phát triển chatbot đa tác tử theo kiến trúc hai lớp. Lớp thứ nhất là đường ống nội bộ được tích hợp trực tiếp trong máy chủ, sử dụng bộ định tuyến dựa trên từ khóa (có dự phòng bằng mô hình ngôn ngữ lớn) để phân loại ý định và bộ điều phối gọi song song các tác tử chuyên biệt. Đây là phương thức xử lý chính, đảm bảo độ trễ thấp và hoạt động ổn định ngay cả khi không có khóa API cho mô hình ngôn ngữ. Lớp thứ hai là Dịch vụ Tác tử – dịch vụ vi mô riêng biệt sử dụng đồ thị trạng thái LangGraph với quy trình tám bước, hỗ trợ suy luận đa bước, lập kế hoạch truy xuất và đánh giá chất lượng. Dịch vụ này được kích hoạt tùy chọn cho các truy vấn phức tạp.

Bước thứ tư là xây dựng giao diện người dùng với Next.js, tập trung vào trải nghiệm người dùng mượt mà và hiệu năng cao. Giao diện được tổ chức thành các thành phần tái sử dụng, với tiện ích chatbot nổi cho phép người dùng tương tác mọi lúc.

Bước cuối cùng là kiểm thử và đảm bảo chất lượng với hơn 55 tập kiểm thử bao phủ tất cả các mô-đun. Các bài kiểm thử bao gồm kiểm thử đơn vị (mô hình, lược đồ, tiện ích), kiểm thử tích hợp (điểm cuối API, thao tác cơ sở dữ liệu) và kiểm thử đầu cuối (đường ống chatbot, nạp dữ liệu).

Đóng góp của đồ án

Đồ án có những đóng góp chính trên nhiều phương diện.

Về mặt ứng dụng, đồ án đã xây dựng một nền tảng bất động sản hoàn chỉnh, sẵn sàng triển khai thực tế, tích hợp công nghệ trí tuệ nhân tạo tiên tiến (tạo sinh tăng cường truy xuất, đa tác tử, tìm kiếm véc-tơ) để giải quyết bài toán tư vấn bất động sản đa lĩnh vực bằng tiếng Việt.

Về mặt kiến trúc, đồ án đề xuất kiến trúc chatbot hai lớp (đường ống nội bộ kết hợp dịch vụ tác tử) với cơ chế dự phòng linh hoạt, đảm bảo hệ thống hoạt động ổn định trong nhiều điều kiện vận hành khác nhau (có hoặc không có khóa API, có hoặc không có dịch vụ tác tử).

Về mặt dữ liệu, đồ án đã xây dựng đường ống thu thập và xử lý dữ liệu bất động sản tự động, hoàn chỉnh từ khâu thu thập đến tạo véc-tơ đặc trưng, có khả năng vận hành định kỳ qua Apache Airflow. Hệ thống kho kiến thức pháp lý cung cấp khả năng xử lý và truy xuất kiến thức pháp lý từ nhiều định dạng tài liệu. **Quy trình thu thập dữ liệu** được thiết kế chi tiết với ba giai đoạn chính: thu thập địa chỉ URL tin đăng qua công cụ tự động hóa trình duyệt với cơ chế ẩn danh và bốn luồng xử lý song song; thu thập chi tiết từng tin với bộ phân tích đầy đủ ba mươi trường thông tin; ghi dữ liệu ra tệp CSV với cơ chế loại bỏ trùng lặp dựa trên mã sản phẩm. **Phương pháp chia đoạn ngữ nghĩa** được thiết kế với bốn loại đoạn cho mỗi bất động sản: đoạn tổng quan (tiêu đề, giá, diện tích, khu vực, pháp lý, nội thất), đoạn mô tả chi tiết, đoạn vị trí (địa chỉ, quận, thành phố) và đoạn nhu cầu (các đặc điểm phù hợp như gần trường học, view đẹp, an ninh). **Cách thức xây dựng hệ thống tạo sinh tăng cường truy xuất** được thực hiện qua năm bước: làm sạch và chuẩn hóa dữ liệu thô; làm giàu với mã hóa địa lý và gán nhãn nhu cầu; chia đoạn ngữ nghĩa đảm bảo mỗi đoạn có thể đứng độc lập; tạo véc-tơ đặc trưng 1024 chiều bằng mô hình BGE-M3 với xử lý theo lô và cơ chế thử lại khi lỗi; nạp vào PostgreSQL với chỉ mục HNSW để tối ưu tìm kiếm lân cận gần nhất. **Các mô-đun chính đã xây dựng** bao gồm: mô-đun thu thập dữ liệu với năm mô-đun con cho từng loại nội dung; mô-đun đường ống xử lý dữ liệu với các bước làm sạch, làm giàu, chia đoạn, tạo véc-tơ và nạp dữ liệu; mô-đun máy chủ dịch vụ với bảy bộ định tuyến API; mô-đun chatbot đa tác tử với bộ định tuyến, bộ điều phối và bốn tác tử chuyên biệt; mô-đun tìm kiếm lai kết hợp tìm kiếm có cấu trúc với tìm kiếm ngữ nghĩa; mô-đun Dịch vụ Tác tử với đồ thị trạng thái tám nút; và mô-đun lập lịch với bốn luồng công việc.

Về mặt kỹ thuật, đồ án đã tích hợp và đánh giá hiệu quả của tìm kiếm lai (kết hợp truy vấn có cấu trúc, tìm kiếm véc-tơ qua chỉ mục HNSW, xếp hạng lại và bộ nhớ đệm Redis) cho bài toán tìm kiếm bất động sản tiếng Việt, với khả năng trích xuất bộ lọc tự động

từ truy vấn ngôn ngữ tự nhiên.

Về mặt vận hành, đồ án đã thiết lập hệ thống quan sát toàn diện (theo dõi vết tác tử, chỉ số giám sát, phản hồi đánh giá) và bộ kiểm thử phong phú, tạo nền tảng vững chắc cho việc phát triển và vận hành hệ thống trong môi trường thực tế.

Bố cục của báo cáo

Báo cáo được tổ chức thành ba chương chính, phần Giới thiệu và phần Kết luận.

Phần **Giới thiệu** trình bày vấn đề về những thách thức trong tiếp cận thông tin bất động sản tại Việt Nam; xác định năm mục tiêu chính của đồ án; phạm vi nghiên cứu về thị trường, loại hình, chức năng và công nghệ; phương pháp tiếp cận theo hướng phát triển mô-đun; và những đóng góp chính của đồ án, trong đó nhấn mạnh quy trình thu thập dữ liệu, phương pháp chia đoạn ngữ nghĩa và cách thức xây dựng hệ thống tạo sinh tăng cường truy xuất.

Chương 1 – Cơ sở lý thuyết trình bày tổng quan về lĩnh vực nghiên cứu gồm nền tảng bất động sản trực tuyến và ứng dụng chatbot trong lĩnh vực này. Tiếp theo là các khái niệm nền tảng: kỹ thuật tạo sinh tăng cường truy xuất, hệ đa tác tử, véc-tơ đặc trưng và tìm kiếm ngữ nghĩa, tìm kiếm lai và xếp hạng lại. Phần cuối chương giới thiệu chi tiết từng công nghệ được sử dụng: FastAPI, Next.js, PostgreSQL với tìm kiếm véc-tơ, LangGraph, Google Gemini, mô hình véc-tơ BGE-M3, mô hình xếp hạng lại, Redis, Apache Airflow và công cụ tự động hóa trình duyệt.

Chương 2 – Phân tích thiết kế hệ thống trình bày toàn bộ quá trình phân tích yêu cầu chức năng (ba nhóm: người dùng cuối, chatbot, quản trị và dữ liệu) và phi chức năng. Tiếp đến là thiết kế kiến trúc tổng thể năm tầng với sơ đồ kiến trúc; thiết kế chi tiết các tầng (giao diện người dùng, máy chủ dịch vụ, dịch vụ tác tử, tầng dữ liệu, đường ống dữ liệu); thiết kế cơ sở dữ liệu với bốn nhóm bảng và chiến lược lập chỉ mục; cùng thiết kế giao diện người dùng cho sáu loại trang chính.

Chương 3 – Triển khai và kiểm thử trình bày chi tiết quy trình triển khai hệ thống với Docker Compose (năm dịch vụ, kiểm tra trạng thái, chuỗi phụ thuộc); cấu hình môi trường và biến môi trường; quy trình tích hợp liên tục và giám sát (chỉ số hệ thống, theo dõi vết tác tử, cảnh báo); lập lịch đường ống với Apache Airflow (bốn luồng công việc); chiến lược kiểm thử đa cấp độ với 58 tệp kiểm thử; kết quả kiểm thử chi tiết theo mười nhóm chức năng; và đánh giá hiệu năng hệ thống.

Phần **Kết luận** tổng kết các kết quả chính đạt được, phân tích những hạn chế hiện tại và đề xuất các hướng phát triển trong tương lai.

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT

Chương này trình bày các khái niệm nền tảng và công nghệ được sử dụng trong đề án. Phần đầu giới thiệu tổng quan về lĩnh vực nghiên cứu: nền tảng bất động sản trực tuyến và ứng dụng của chatbot trong lĩnh vực này. Phần tiếp theo đi sâu vào các khái niệm cốt lõi: kỹ thuật tạo sinh tăng cường truy xuất, hệ đa tác tử, véc-tơ đặc trưng và tìm kiếm ngữ nghĩa, tìm kiếm lai và xếp hạng lại. Phần cuối cùng giới thiệu chi tiết từng công nghệ được sử dụng trong hệ thống, từ giao diện người dùng, máy chủ dịch vụ, cơ sở dữ liệu đến trí tuệ nhân tạo và đường ống dữ liệu.

1.1. Tổng quan về lĩnh vực nghiên cứu

1.1.1. Nền tảng bất động sản trực tuyến

Các nền tảng bất động sản trực tuyến đóng vai trò trung gian kết nối người mua, người bán và nhà đầu tư. Tại Việt Nam, batdongsan.com.vn là cổng thông tin bất động sản lớn nhất với hàng chục nghìn tin đăng mới mỗi ngày, bao gồm cả tin bán và cho thuê với đa dạng loại hình: căn hộ chung cư, nhà riêng, nhà mặt phố, đất nền, biệt thự và nhà phố thương mại (shophouse). Các nền tảng này thường cung cấp chức năng đăng tin, tìm kiếm theo bộ lọc cơ bản (giá, diện tích, khu vực) và hiển thị thông tin chi tiết của từng bất động sản.

Tuy nhiên, các nền tảng hiện tại còn tồn tại nhiều hạn chế:

- **Tìm kiếm dựa trên từ khóa chính xác:** Hệ thống chỉ khớp chính xác từ khóa người dùng nhập với nội dung tin đăng, không hiểu được ngữ nghĩa và ngữ cảnh của truy vấn. Ví dụ, truy vấn “căn hộ thoáng mát, view đẹp” không thể được xử lý hiệu quả bằng SQL WHERE thông thường.
- **Thiếu tư vấn tổng hợp:** Người dùng phải tự tổng hợp thông tin từ nhiều tin đăng khác nhau để đưa ra quyết định. Không có cơ chế tự động phân tích xu hướng thị trường, so sánh giá giữa các khu vực, hay đánh giá tiềm năng đầu tư.
- **Không có hỗ trợ pháp lý:** Các vấn đề pháp lý (sổ đỏ, quy hoạch, thủ tục sang tên, thuế phí) là mối quan tâm hàng đầu của người mua nhưng không được các nền tảng đề cập đến một cách có hệ thống.
- **Dữ liệu không được tổ chức cho AI:** Dữ liệu trên các nền tảng được thiết kế để hiển thị cho con người đọc, không được cấu trúc và đánh chỉ mục để phục vụ các hệ thống truy xuất thông tin (information retrieval) và sinh văn bản (text generation).

1.1.2. Chatbot và trợ lý ảo trong bất động sản

Chatbot trong lĩnh vực bất động sản có tiềm năng tự động hóa quy trình tư vấn, giảm tải cho nhân viên môi giới và cung cấp dịch vụ liên tục cho khách hàng. Sự phát triển của các mô hình ngôn ngữ lớn như GPT-4, Google Gemini, Claude đã mở ra khả năng xây dựng các chatbot thông minh, có khả năng hiểu ngôn ngữ tự nhiên và sinh phản hồi mạch lạc.

Tuy nhiên, mô hình ngôn ngữ lớn thuần túy có hai hạn chế lớn khi áp dụng vào lĩnh vực bất động sản. Thứ nhất là hiện tượng ảo giác: mô hình có thể sinh ra thông tin không chính xác về giá cả, vị trí hoặc tình trạng pháp lý của bất động sản – những thông tin đòi hỏi độ chính xác tuyệt đối trong giao dịch thực tế. Thứ hai là thông tin lỗi thời: mô hình được huấn luyện trên dữ liệu có thời điểm cắt nhất định, không thể cập nhật theo biến động hàng ngày của thị trường bất động sản.

Để khắc phục, các hệ thống chatbot hiện đại kết hợp mô hình ngôn ngữ với kỹ thuật tạo sinh tăng cường truy xuất, cho phép mô hình truy xuất thông tin từ cơ sở dữ liệu ngoài trước khi sinh phản hồi. Cách tiếp cận này đảm bảo phản hồi dựa trên dữ liệu thực tế, có thể kiểm chứng và luôn được cập nhật.

1.2. Các khái niệm cơ bản

1.2.1. Kỹ thuật tạo sinh tăng cường truy xuất

Kỹ thuật tạo sinh tăng cường truy xuất (Retrieval-Augmented Generation – RAG) là kỹ thuật kết hợp giữa truy xuất thông tin và sinh văn bản, được đề xuất bởi Lewis và cộng sự (2020). Quy trình gồm ba bước chính: truy xuất, tăng cường và sinh.

1. **Truy xuất (Retrieve):** Khi nhận được câu hỏi của người dùng, hệ thống chuyển câu hỏi thành vector embedding (sử dụng cùng mô hình embedding với dữ liệu) và tìm kiếm k đoạn văn bản (chunks) có độ tương đồng cao nhất trong cơ sở dữ liệu vector. Phép đo tương đồng thường dùng là cosine similarity:

$$\text{sim}(\mathbf{q}, \mathbf{d}_i) = \frac{\mathbf{q} \cdot \mathbf{d}_i}{\|\mathbf{q}\| \|\mathbf{d}_i\|} \quad (1.1)$$

trong đó $\mathbf{q}$ là vector embedding của câu truy vấn, $\mathbf{d}_i$ là vector embedding của chunk thứ i .

2. **Tăng cường (Augment):** Các chunks được truy xuất sẽ được đưa vào prompt của LLM như ngữ cảnh bổ sung (context). Prompt thường có cấu trúc: system instruction + retrieved context + user query. Việc này giúp LLM có thông tin thực tế để dựa vào khi sinh câu trả lời.

3. **Sinh (Generate):** LLM sinh câu trả lời dựa trên câu hỏi gốc và ngữ cảnh được cung cấp, kèm theo trích dẫn nguồn (citations) cho phép người dùng kiểm chứng thông tin.

Ưu điểm của RAG:

- **Giảm thiểu ảo giác:** Phản hồi được neo (grounded) vào dữ liệu thực tế thay vì chỉ dựa vào kiến thức nội tại của LLM.
- **Thông tin cập nhật:** Cơ sở dữ liệu vector có thể được cập nhật liên tục mà không cần fine-tune lại LLM.
- **Kiểm chứng được:** Mỗi phản hồi đi kèm danh sách nguồn tham khảo, cho phép người dùng xác minh.
- **Domain-specific:** Có thể dễ dàng áp dụng cho lĩnh vực chuyên biệt (bất động sản, y tế, pháp luật) bằng cách xây dựng kho dữ liệu riêng.

Các biến thể RAG trong đồ án:

- **Simple RAG:** Truy xuất đơn giản – query embedding → vector search → LLM generation. Được sử dụng làm fallback trong chatbot pipeline.
- **Agent-based RAG:** Mỗi agent chuyên biệt thực hiện truy xuất riêng cho domain của mình (property, market, legal, investment), sau đó kết quả được tổng hợp.
- **Multi-step RAG (Agent Service):** Sử dụng retrieval planner để lập kế hoạch truy xuất qua nhiều bước, mỗi bước có thể truy xuất từ các nguồn khác nhau.

1.2.2. Hệ đa tác tử

Hệ đa tác tử (Multi-Agent System – MAS) là kiến trúc trong đó nhiều tác tử chuyên biệt cùng phối hợp để giải quyết một nhiệm vụ phức tạp. Mỗi agent đảm nhận một vai trò riêng, có system prompt riêng, và có thể truy cập các công cụ (tools) khác nhau. Kiến trúc này phù hợp với bài toán tư vấn bất động sản vì một truy vấn của người dùng thường liên quan đến nhiều khía cạnh: tìm kiếm, thị trường, pháp lý và đầu tư.

Trong đồ án, hệ thống multi-agent được triển khai theo hai lớp:

Lớp 1: Pipeline nội bộ (backend/app/services/chatbot/)

Đây là pipeline chính phục vụ người dùng cuối, hoạt động theo cơ chế:

1. **Router** – Phân loại ý định người dùng. Hỗ trợ hai phương thức:

- *Keyword-based routing*: Sử dụng biểu thức chính quy (regex) và từ khóa tiếng Việt đã chuẩn hóa (không dấu) để nhận diện ý định. Ví dụ: các từ khóa “pháp lý”, “so do”, “cong chung” kích hoạt `legal_advisor`; “đầu tư”, “loại nhuận”, “sinh lời” kích hoạt `investment_advisor`. Phương thức này hoạt động không cần API key, đảm bảo tính sẵn sàng của hệ thống.
 - *Gemini-based routing*: Khi `GEMINI_API_KEY` được cấu hình, sử dụng Google Gemini 2.0 Flash để phân loại ý định với độ chính xác cao hơn. Router gửi prompt chứa danh sách intent có thể và yêu cầu Gemini trả về JSON với intent và target agents.
2. **Orchestrator** – Nhận kết quả routing, chọn các agent tương ứng và gọi chúng song song qua `asyncio.gather()`. Sau khi tất cả agent hoàn thành, orchestrator tổng hợp kết quả: ghép nội dung, gộp danh sách nguồn, loại bỏ suggested actions trùng lặp.
3. **4 Agent chuyên biệt** – Mỗi agent nhận query, routing decision và database session, thực hiện truy xuất riêng và trả về `AgentResult`:
- **Property Search Agent (agents/property.py)**: Trích xuất bộ lọc từ truy vấn (giá, diện tích, khu vực, loại hình) bằng `extract_search_filters()`, thực hiện hybrid search trên bảng listings, định dạng kết quả thành danh sách bất động sản kèm giải thích.
 - **Market Analysis Agent (agents/market.py)**: Truy vấn thông kê thị trường (giá trung bình, số lượng tin, phân bố) từ bảng listings, cung cấp phân tích xu hướng theo khu vực và loại hình.
 - **Legal Advisor Agent (agents/legal.py)**: Tìm kiếm trong legal knowledge base (articles có category liên quan đến pháp lý) để cung cấp thông tin về thủ tục, quy định và lưu ý pháp lý.
 - **Investment Advisor Agent (agents/investment.py)**: Phân tích khả năng sinh lời dựa trên giá, vị trí và xu hướng thị trường; đưa ra đánh giá sơ bộ về tiềm năng đầu tư.

Lớp thứ hai: Dịch vụ Tác tử

Dịch vụ Tác tử là dịch vụ vi mô riêng biệt chạy trên cổng 8100, sử dụng LangGraph để điều phối quy trình đa tác tử. Đồ thị trạng thái bao gồm 14 nút được tổ chức thành bốn nhóm chức năng chính:

Nhóm chuẩn bị và định tuyến gồm: xây dựng ngữ cảnh hội thoại từ lịch sử trò chuyện và sở thích người dùng; kiểm tra trạng thái sẵn sàng của các nguồn dữ liệu (bất động sản, dự án, bài viết, kho kiến thức pháp lý); phân loại ý định và chọn tác tử mục tiêu; phát hiện nhu cầu làm rõ truy vấn khi câu hỏi không đủ thông tin; và phân tích sâu ngữ nghĩa truy vấn để trích xuất thực thể và ràng buộc.

Nhóm truy xuất và xử lý chuyên biệt gồm: lập kế hoạch truy xuất đa bước, xác định nguồn dữ liệu cần truy vấn, bộ lọc và độ ưu tiên; thực thi song song các tác tử chuyên biệt được chọn, mỗi tác tử sử dụng mô hình ngôn ngữ Gemini kết hợp với công cụ truy xuất và thống kê; và nút phân tích đầu tư chạy mô hình đánh giá tài chính cho các bất động sản được tư vấn đầu tư.

Nhóm tổng hợp và kiểm tra gồm: tổng hợp kết quả từ các tác tử thành phản hồi cuối cùng mạch lạc, ưu tiên thông tin có độ tin cậy cao và loại bỏ trùng lặp; và kiểm tra an toàn phản hồi về bốn tiêu chí: tính có căn cứ, tính hữu ích, an toàn và chất lượng trích dẫn.

Nhóm phản ứng và cải thiện gồm: bộ điều khiển phản ứng quyết định có cần truy xuất thêm hoặc chạy lại tác tử khi phát hiện thiếu bằng chứng; nút truy xuất phản ứng thực hiện truy vấn bổ sung; và nút đánh giá hội đồng để xem xét chéo kết quả giữa các tác tử. Cuối cùng, nút đề xuất ghi nhớ trích xuất sở thích người dùng từ hội thoại và tạo đề xuất để lưu vào hệ thống.

Cơ chế ghi nhớ người dùng

Hệ thống tích hợp cơ chế ghi nhớ thông qua hai bảng trong cơ sở dữ liệu. Bảng Sở thích người dùng lưu trữ các sở thích đã được xác nhận dưới dạng khóa-giá trị (ví dụ: thành phố ưa thích là Hồ Chí Minh, ngân sách tối đa 3 tỷ đồng). Mỗi sở thích có điểm tin cậy và được gán nhãn nguồn gốc (do người dùng khai báo, do tác tử đề xuất, hay do hệ thống tự suy luận). Bảng Đề xuất ghi nhớ lưu trữ các đề xuất sở thích được tác tử trích xuất từ hội thoại nhưng chưa được người dùng xác nhận. Mỗi đề xuất mang trạng thái: đang chờ, đã chấp nhận hoặc đã từ chối.

Một số sở thích được tự động áp dụng khi điểm tin cậy đạt ngưỡng 80% (thành phố, quận, loại hình bất động sản, ngân sách tối đa và tối thiểu). Các sở thích khác cần người dùng xác nhận thông qua API.

1.2.3. Véc-tơ đặc trưng và Tìm kiếm ngữ nghĩa

Véc-tơ đặc trưng

Véc-tơ đặc trưng là kỹ thuật chuyển đổi văn bản thành một véc-tơ số thực d -chiều trong không gian Euclid, sao cho các văn bản có ngữ nghĩa tương đồng sẽ nằm gần nhau

trong không gian này. Khoảng cách giữa hai véc-tơ thường được đo bằng độ tương đồng cosin hoặc khoảng cách Euclid (L2).

Đồ án sử dụng mô hình **BGE-M3** (BAAI/bge-m3) – một mô hình embedding đa ngôn ngữ mã nguồn mở, hỗ trợ hơn 100 ngôn ngữ bao gồm tiếng Việt. Các đặc điểm kỹ thuật của BGE-M3 trong đồ án:

- **Không gian embedding:** 1024 chiều.
- **Normalize embeddings:** True (chuẩn hóa về unit vector để dùng cosine similarity hiệu quả).
- **Max sequence length:** 8192 tokens.
- **Batch size:** 16 văn bản mỗi lần encode.
- **Retry policy:** 3 lần thử với exponential backoff.
- **Device:** Tự động chọn CPU/GPU dựa trên cấu hình.

Mô hình được sử dụng cho hai mục đích: (1) tạo embedding cho toàn bộ dữ liệu (listings, projects, articles, legal docs) trong quá trình indexing, và (2) tạo embedding cho câu truy vấn của người dùng trong quá trình tìm kiếm. Cùng một mô hình được dùng cho cả indexing và querying để đảm bảo tính nhất quán của không gian vector.

Tìm kiếm ngữ nghĩa (Semantic Search)

Tìm kiếm ngữ nghĩa sử dụng vector embedding để tìm các đoạn văn bản có nội dung tương đồng với câu truy vấn, ngay cả khi không có từ khóa chung. Đồ án sử dụng **pgvector** – extension của PostgreSQL – để lưu trữ và tìm kiếm vector. Cụ thể:

- **Kiểu dữ liệu:** `VECTOR(1024)` – lưu vector 1024 chiều.
- **Độ đo:** Cosine distance (`<=>` operator trong pgvector).
- **Chỉ mục:** HNSW (Hierarchical Navigable Small World) – cấu trúc chỉ mục xấp xỉ cho tìm kiếm k-NN hiệu quả với tham số $m = 16$ (số kết nối mỗi node) và `ef_construction = 64` (kích thước danh sách động khi xây dựng).

1.2.4. Tìm kiếm lai và Xếp hạng lại

Tìm kiếm lai

Tìm kiếm lai kết hợp hai phương pháp tìm kiếm bổ trợ:

1. **Structured Filtering (SQL WHERE):** Áp dụng các bộ lọc có cấu trúc trên các trường quan hệ – listing_type (sale/rent), property_type, city, district, price (min/max), area (min/max), bedrooms. Điều này đảm bảo kết quả chính xác về mặt thuộc tính.
2. **Semantic Search (pgvector kNN):** Sử dụng vector embedding để tìm các chunks có nội dung tương đồng ngữ nghĩa với câu truy vấn. Điều này cho phép tìm thấy các bất động sản phù hợp với mô tả mềm (“view đẹp”, “gần trường học”, “khu an ninh”).

Hai phương pháp được kết hợp trong cùng một truy vấn SQL: đầu tiên lọc theo điều kiện WHERE trên bảng listings, sau đó join với bảng chunks và sắp xếp theo cosine distance trên cột embedding. Kết quả cuối cùng là danh sách k bất động sản vừa thỏa mãn bộ lọc cứng, vừa có nội dung mô tả phù hợp ngữ nghĩa.

Reranking (Xếp hạng lại)

Sau khi có tập kết quả ứng viên từ hybrid search, kỹ thuật reranking được áp dụng để sắp xếp lại theo độ liên quan thực tế. Đồ án sử dụng **Cohere Rerank Multilingual v3.0** – mô hình Cross-Encoder chuyên dụng:

- **Nguyên lý:** Không giống như Bi-Encoder (mã hóa query và document riêng biệt rồi so sánh), Cross-Encoder xử lý cặp (query, document) đồng thời qua cùng một mạng, cho phép mô hình học được mối tương tác tinh tế giữa chúng. Điều này cho độ chính xác cao hơn đáng kể, đặc biệt với các truy vấn phức tạp.
- **Cách sử dụng trong đồ án:** Gọi Cohere API với query gốc và danh sách documents (nội dung các chunks đã truy xuất), nhận về relevance score cho từng cặp. Kết quả được sắp xếp lại theo score giảm dần và lấy top_n = 5 kết quả tốt nhất. Reranking được áp dụng tùy chọn (khi COHERE_API_KEY được cấu hình).

Redis Caching

Để giảm độ trễ cho các truy vấn lặp lại, hệ thống tích hợp Redis caching ở hai cấp độ:

- **Embedding cache:** Cache vector embedding của câu truy vấn (key là hash của query text + model name + dimension). Điều này đặc biệt hữu ích khi nhiều agent cùng truy xuất với cùng một query.
- **Search result cache:** Cache kết quả hybrid search (key là hash của query + filters). Thời gian sống (TTL) mặc định được cấu hình để cân bằng giữa freshness và hiệu năng.

1.3. Các công nghệ sử dụng

1.3.1. FastAPI

FastAPI là web framework Python hiện đại, được xây dựng trên nền tảng Starlette (ASGI) và Pydantic. Các đặc điểm chính:

- **Hiệu năng cao:** FastAPI là một trong những Python framework nhanh nhất, ngang hàng với Node.js và Go, nhờ kiến trúc bất đồng bộ (async/await) và ASGI.
- **Async database:** Tích hợp SQLAlchemy 2.0 async với asyncpg driver, cho phép xử lý database I/O không chặn (non-blocking). Connection pool được cấu hình với `pool_size=20` và `max_overflow=10`.
- **Validation tự động:** Pydantic v2 cung cấp validation dữ liệu đầu vào/đầu ra với type hints, tự động sinh JSON Schema và tài liệu OpenAPI.
- **Dependency injection:** Cơ chế Depends() cho phép tái sử dụng logic (database session, authentication, rate limiting) một cách sạch sẽ.
- **Tài liệu tương tác:** Swagger UI (/docs) và ReDoc được sinh tự động từ code.

Trong đồ án, FastAPI được sử dụng cho cả Backend API (cổng 8000) và Agent Service (cổng 8100).

1.3.2. Next.js

Next.js là React framework hỗ trợ Server-Side Rendering (SSR), Static Site Generation (SSG), Incremental Static Regeneration (ISR) và App Router (từ phiên bản 13+). Đồ án sử dụng Next.js 16 với React 19:

- **App Router:** Tổ chức trang theo cấu trúc thư mục `app/`, mỗi thư mục là một route segment. Hỗ trợ layouts lồng nhau, loading states, error boundaries.
- **Server Components:** Mặc định các component là React Server Components (RSC), giảm lượng JavaScript gửi về client.
- **Tailwind CSS v4:** Utility-first CSS framework cho phép xây dựng giao diện nhanh, nhất quán, không cần viết CSS thủ công.
- **SSR cho SEO:** Các trang danh sách và chi tiết bất động sản được render phía server, đảm bảo nội dung có sẵn cho crawler của công cụ tìm kiếm.
- **API client:** File `lib/api.ts` định nghĩa typed API client với các hàm gọi backend FastAPI, sử dụng fetch API với JWT token trong Authorization header.

1.3.3. PostgreSQL + pgvector

PostgreSQL là hệ quản trị cơ sở dữ liệu quan hệ mã nguồn mở, được sử dụng làm cơ sở dữ liệu chính của hệ thống. Extension **pgvector** bổ sung khả năng lưu trữ và tìm kiếm vector, biến PostgreSQL thành vector database:

- **Kiểu dữ liệu VECTOR:** Lưu vector d -chiều (trong đề án: 1024) dưới dạng chuỗi bytes tối ưu.
- **Phép toán tương đồng:** Hỗ trợ 3 độ đo khoảng cách:
 - $\langle - \rangle$ – Euclidean distance (L2).
 - $\langle \# \rangle$ – Negative inner product.
 - $\langle = \rangle$ – Cosine distance (được sử dụng trong đề án).
- **HNSW Index:** Chỉ mục xấp xỉ cho tìm kiếm k-NN nhanh. Trong đề án, HNSW index được tạo trực tiếp trong model definition qua `Index()` với `postgresql_using="hnsw"` và `postgresql_ops={"embedding": "vector_cosine_ops"}`.
- **Ưu điểm so với dedicated vector DB:** Dữ liệu quan hệ (listings, users, chats) và dữ liệu vector (chunks, embeddings) nằm trong cùng một hệ thống, cho phép JOIN, filter, và transaction ACID trên cả hai loại dữ liệu. Giảm độ phức tạp vận hành (chỉ cần quản lý một database).

1.3.4. LangGraph

LangGraph là thư viện của LangChain cho phép xây dựng các ứng dụng multi-agent có trạng thái (stateful) dưới dạng đồ thị có hướng (Directed Graph). Các khái niệm chính:

- **StateGraph:** Đồ thị trạng thái trong đó mỗi node nhận state object, xử lý và trả về state đã cập nhật. State được định nghĩa bởi TypedDict hoặc Pydantic model.
- **Nodes:** Các hàm xử lý (có thể là sync hoặc async) đại diện cho một bước trong pipeline. Trong đề án, Agent Service có 8 nodes.
- **Edges:** Kết nối có hướng giữa các nodes, xác định luồng xử lý. Có hai loại: normal edge (luôn đi từ A đến B) và conditional edge (chọn node tiếp theo dựa trên state).
- **Checkpointing:** Lưu trạng thái sau mỗi bước, cho phép resume từ điểm dừng và debug.

Trong đồ án, LangGraph được sử dụng trong Agent Service (`agent_service/graph/world`) với StateGraph được compile và chạy qua `chat_graph.invoke().State object` (AgentGraphS theo dõi toàn bộ quá trình xử lý: request gốc, intent, retrieval plan, kết quả từng agent, final response, sources, trace steps, warnings).

Pipeline nội bộ trong backend (`chatbot/orchestrator.py`) không sử dụng LangGraph mà dùng cơ chế đơn giản hơn: router chọn agents, `asyncio.gather()` chạy song song, và combine kết quả.

1.3.5. Google Gemini

Google Gemini 2.0 Flash là mô hình ngôn ngữ lớn đa năng của Google, hỗ trợ đa ngôn ngữ (bao gồm tiếng Việt) với khả năng sinh văn bản, phân loại và tạo embedding. Trong đồ án, Gemini được sử dụng cho ba nhiệm vụ:

- 1. Intent Router (Gemini-based routing):** Khi `GEMINI_API_KEY` được cấu hình, router sử dụng Gemini để phân loại ý định người dùng thay vì keyword matching. Prompt yêu cầu Gemini phân tích query và trả về JSON với intent và danh sách target agents phù hợp. Điều này cho độ chính xác cao hơn với các truy vấn phức tạp hoặc mơ hồ.
- 2. LLM cho Agent Service:** Trong Agent Service, Gemini được sử dụng làm LLM chính cho các specialist agents (qua GeminiClient wrapper trong `agent_service/llm/gemini`). Mỗi agent nhận system prompt mô tả vai trò, context từ retrieval, và sinh phản hồi chuyên biệt.
- 3. LLM Judge:** Gemini được sử dụng để đánh giá chất lượng phản hồi của chatbot qua 5 tiêu chí: groundedness (tính có căn cứ), helpfulness (tính hữu ích), citation_quality (chất lượng trích dẫn), safety (an toàn), và trace_completeness (tính đầy đủ của trace). Prompt judge được viết bằng tiếng Việt và yêu cầu output JSON.

Cơ chế fallback: Khi `GEMINI_API_KEY` không được cấu hình, hệ thống tự động chuyển sang keyword-based routing cho intent classification. Các agent trong pipeline nội bộ có thể hoạt động không cần LLM (dùng template-based response từ dữ liệu truy xuất). Điều này đảm bảo hệ thống luôn hoạt động được ngay cả khi không có kết nối đến Gemini API.

1.3.6. BGE-M3 Embedding

BGE-M3 (BAAI/bge-m3) là mô hình embedding đa ngôn ngữ mã nguồn mở từ BAAI (Beijing Academy of Artificial Intelligence), hỗ trợ hơn 100 ngôn ngữ bao gồm tiếng Việt.

Đây là mô hình embedding chính của đề án, được chọn vì các lý do:

- **Chất lượng cao cho tiếng Việt:** BGE-M3 được huấn luyện trên corpus đa ngôn ngữ lớn, cho chất lượng embedding tốt với văn bản tiếng Việt – vượt trội so với Gemini Embedding trong các thử nghiệm nội bộ.
- **Không phụ thuộc API:** Là mô hình mã nguồn mở, chạy local qua thư viện `sentence-transformers` không giới hạn về số lượng request hay chi phí API. Điều này đặc biệt quan trọng khi cần tạo embedding cho hàng trăm nghìn chunks.
- **Hỗ trợ batch processing:** BGEEmbedder trong đề án (`rag/embeddings.py`) hỗ trợ encode theo batch (`batch_size=16`), chạy async qua `asyncio.to_thread()` để không chặn event loop.
- **Multi-granularity:** BGE-M3 hỗ trợ cả dense embedding (1024 chiều), sparse embedding (lexical), và multi-vector – mặc dù đề án hiện chỉ sử dụng dense embedding.

1.3.7. Cohere Rerank

Cohere Rerank Multilingual v3.0 là mô hình Cross-Encoder chuyên dụng cho bài toán xếp hạng lại kết quả truy xuất. So với cách tiếp cận Bi-Encoder (tạo embedding riêng cho query và document):

- **Kiến trúc Cross-Encoder:** Xử lý cặp (query, document) đồng thời qua cùng một mạng transformer, cho phép mô hình học được mối tương tác tinh tế giữa chúng. Điều này cho độ chính xác cao hơn đáng kể so với so sánh cosine similarity của Bi-Encoder.
- **Đa ngôn ngữ:** Hỗ trợ tiếng Việt và nhiều ngôn ngữ khác, phù hợp với dữ liệu bất động sản tiếng Việt.
- **Sử dụng trong đề án:** Gọi qua HTTP API (`httpx client`), gửi query và danh sách documents, nhận relevance score cho từng cặp. Kết quả được lọc theo `RERANK_TOP_N` (mặc định: 5).
- **Cấu hình linh hoạt:** Reranking có thể bật/tắt qua biến môi trường (`RERANK_PROVIDER`), cho phép hệ thống hoạt động không cần Cohere API key.

1.3.8. Redis

Redis (Remote Dictionary Server) là cơ sở dữ liệu key-value in-memory, được sử dụng làm cache trong đề án:

- **Embedding cache:** Lưu vector embedding của query để tránh encode lại. Key format: `embedding:{provider}:{model}:{dimension}:{hash}`.
- **Search cache:** Lưu kết quả hybrid search để phục vụ truy vấn lặp lại. Sử dụng JSON serialization qua `JsonCache` class.
- **Session store:** Lưu trữ session state tạm thời cho chat.
- **Health check:** Docker healthcheck sử dụng `redis-cli ping`.

1.3.9. Apache Airflow

Apache Airflow là nền tảng quản lý workflow mã nguồn mở, cho phép định nghĩa, lập lịch và giám sát các pipeline dữ liệu dưới dạng DAG (Directed Acyclic Graph). Trong đề án, Airflow quản lý 4 DAGs:

- **daily_listings_dag:** Chạy hàng ngày lúc 02:00 (giờ Hồ Chí Minh). Gồm 8 tasks: `crawl_sale_urls` → `crawl_sale_details` → `ingest_sale` (cùng lúc với `crawl_rent_urls` → `crawl_rent_details` → `ingest_rent`) → `mark_active` → `chunk_and_embed`. Sử dụng `watermark (-since)` để chỉ crawl tin mới.
- **weekly_projects_dag:** Chạy hàng tuần vào Chủ nhật 03:00. Crawl thông tin dự án bất động sản (tên, chủ đầu tư, vị trí, quy mô, tiện ích) và nạp vào bảng `projects`.
- **weekly_news_dag:** Chạy hàng tuần vào Chủ nhật 04:00. Crawl tin tức và bài viết phân tích thị trường, nạp vào bảng `articles`.
- **monthly_legal_kb_dag:** Chạy hàng tháng vào ngày 1 lúc 05:00. Xử lý lại toàn bộ tài liệu pháp lý từ thư mục `data/knowledge/`, bao gồm cả HTML và PDF, tạo chunks và embedding mới.

Mỗi DAG được cấu hình retry 3 lần với exponential backoff (5 phút → 10 phút → 20 phút, tối đa 30 phút). Cơ chế cảnh báo qua Slack và email được tích hợp khi task thất bại. Metrics được ghi vào bảng `pipeline_runs` để theo dõi hiệu suất.

1.3.10. Playwright

Playwright là thư viện tự động hóa trình duyệt do Microsoft phát triển, hỗ trợ Chromium, Firefox và WebKit. Trong đề án, Playwright được sử dụng để crawl dữ liệu từ `batdongsan.com.vn`:

- **Stealth mode:** Cấu hình trình duyệt với các kỹ thuật chống phát hiện (stealth) để tránh bị chặn bởi cơ chế anti-bot của website.

- **Parallel workers:** Sử dụng đa luồng (4 workers) để crawl song song nhiều trang, tăng tốc độ thu thập dữ liệu.
- **Phân chia module:** Crawler được tổ chức thành các module riêng biệt cho từng loại nội dung: `crawler/sale/` (tin bán), `crawler/rent/` (tin cho thuê), `crawler/project` (dự án), `crawler/news/` (tin tức). Mỗi module có hai bước: crawl URL và crawl chi tiết.
- **CSV output:** Dữ liệu được ghi vào file CSV với encoding UTF-8 BOM, hỗ trợ deduplication qua `product_id` và merge các file tạm.
- **Core infrastructure:** `crawler/core/` chứa các thành phần dùng chung: `csv_writer` (ghi CSV với dedup), `parser` (parse thông tin cơ bản), `listing_detail_parser` (parse chi tiết listing với đầy đủ trường).

1.3.11. Các thư viện và công cụ khác

- **SQLAlchemy 2.0:** ORM cho Python với hỗ trợ `async/await` qua `asyncpg` driver. Được sử dụng để định nghĩa models, thực hiện truy vấn và quản lý schema.
- **Pydantic v2:** Thư viện validation dữ liệu sử dụng type hints. Được sử dụng cho request/response schemas trong FastAPI và internal contracts giữa các service.
- **bcrypt:** Thư viện hash mật khẩu với salt, được sử dụng trong authentication flow.
- **PyJWT:** Thư viện tạo và xác thực JSON Web Token, với thuật toán HS256 và thời hạn 24 giờ.
- **HTTPX:** HTTP client bất đồng bộ, được sử dụng để gọi Cohere Rerank API và internal Agent Service API.
- **Docker & Docker Compose:** Containerization cho toàn bộ hệ thống với 5 service, health checks, và volume mounts.
- **Prometheus:** Hệ thống giám sát và thu thập metrics, tích hợp qua endpoint `/api/v1/metrics` với các counter cho chat requests, retrieval latency và pipeline runs.

CHƯƠNG 2. PHÂN TÍCH THIẾT KẾ HỆ THỐNG

Chương này trình bày toàn bộ quá trình phân tích và thiết kế hệ thống. Nội dung bao gồm: phân tích yêu cầu chức năng và phi chức năng, thiết kế kiến trúc tổng thể theo mô hình dịch vụ vi mô, thiết kế chi tiết các mô-đun thành phần (giao diện người dùng, máy chủ dịch vụ, dịch vụ tác tử, đường ống dữ liệu), thiết kế cơ sở dữ liệu quan hệ kết hợp véc-tơ, thiết kế giao diện người dùng, quy trình triển khai với Docker và kết quả kiểm thử hệ thống.

2.1. Phân tích yêu cầu

2.1.1. Yêu cầu chức năng

Hệ thống phục vụ ba nhóm đối tượng chính: người dùng cuối (người mua, người thuê, nhà đầu tư), quản trị viên hệ thống, và bản thân hệ thống (các tác vụ tự động). Dưới đây là các nhóm chức năng được phân tích chi tiết.

Nhóm chức năng dành cho người dùng cuối

Đây là nhóm chức năng cốt lõi, quyết định trải nghiệm của người dùng khi tương tác với nền tảng:

1. Xác thực và quản lý tài khoản:

- Đăng ký tài khoản mới với email và mật khẩu. Mật khẩu được hash bằng bcrypt trước khi lưu trữ.
- Đăng nhập bằng email/mật khẩu, hệ thống trả về JWT token có thời hạn 24 giờ. Token được lưu ở client (localStorage) và gửi kèm trong Authorization header cho các request tiếp theo.
- Người dùng chưa đăng nhập (anonymous) vẫn có thể sử dụng chatbot với giới hạn 20 lượt/ngày. Người dùng đã xác thực được nâng lên 200 lượt/ngày.
- Hồ sơ người dùng bao gồm: họ tên, email, số điện thoại, ảnh đại diện, quyền (is_admin, is_superuser).

2. Duyệt và tìm kiếm bất động sản:

- **Danh sách bất động sản bán:** Hiển thị dưới dạng lưới thẻ (card grid) với phân trang (pagination). Mỗi thẻ hiển thị: tiêu đề, giá, diện tích, địa chỉ (quận, thành phố), số phòng ngủ, loại tin (VIP/thường).

- **Danh sách bất động sản cho thuê:** Tương tự như trang bán nhưng dành riêng cho tin cho thuê.
- **Bộ lọc nâng cao:** Người dùng có thể lọc theo 10+ tiêu chí: loại tin (bán/cho thuê), loại hình bất động sản (căn hộ, nhà riêng, đất nền, biệt thự,...), thành phố, quận/huyện, khoảng giá (từ – đến), diện tích (từ – đến), số phòng ngủ, số phòng tắm, hướng nhà.
- **Tìm kiếm theo từ khóa:** Hỗ trợ tìm kiếm full-text trên các trường tiêu đề, mô tả, địa chỉ, quận, thành phố.
- **Sắp xếp kết quả:** Theo giá tăng dần/giảm dần, diện tích tăng dần/giảm dần, mới nhất.

3. Xem chi tiết bất động sản:

- Trang chi tiết hiển thị đầy đủ thông tin của một bất động sản: tiêu đề, mô tả chi tiết, giá (dạng số + text), đơn giá theo m^2 , diện tích (dạng số + text), địa chỉ đầy đủ (phường/xã, quận/huyện, tỉnh/thành phố), tọa độ địa lý (latitude, longitude).
- Thông số kỹ thuật: số phòng ngủ, số phòng tắm, số tầng, hướng nhà, hướng ban công, mặt tiền, đường vào.
- Thông tin pháp lý và nội thất: tình trạng pháp lý (sổ đỏ, sổ hồng,...), tình trạng nội thất (đầy đủ, cơ bản, bàn giao thô).
- Thông tin liên hệ: tên và số điện thoại người đăng.
- **Bất động sản tương tự:** Hệ thống tự động gợi ý các bất động sản có đặc điểm tương đồng (cùng khu vực, cùng phân khúc giá, cùng loại hình).

4. Thống kê và phân tích thị trường:

- **Tổng quan thị trường:** Hiển thị các chỉ số chính: tổng số tin đăng đang hoạt động, giá trung bình, diện tích trung bình, số lượng tin bán và cho thuê, số thành phố và quận/huyện có dữ liệu.
- **Top khu vực:** Bảng xếp hạng các thành phố/quận có nhiều tin đăng nhất, có thể lọc theo loại tin.
- **Thống kê giá theo quận:** Với mỗi quận trong một thành phố, hiển thị số lượng tin, giá trung bình, giá thấp nhất, giá cao nhất và đơn giá trung bình/ m^2 .
- **Phân bố loại hình:** Thống kê số lượng tin theo từng loại hình bất động sản (căn hộ, nhà riêng, đất nền,...).

5. Tương tác với chatbot tư vấn:

- **Chat widget nổi:** Luôn hiển thị ở góc phải dưới màn hình, có thể mở rộng/thu gọn. Người dùng có thể đặt câu hỏi bất kỳ lúc nào.
- **Hội thoại đa lượt:** Hệ thống lưu trữ toàn bộ lịch sử hội thoại theo phiên (session). Người dùng có thể xem lại các phiên chat trước đó.
- **Phản hồi có trích dẫn nguồn:** Mỗi câu trả lời của chatbot đều kèm danh sách nguồn tham khảo (tên bất động sản, đường dẫn, điểm liên quan), cho phép người dùng kiểm chứng thông tin.
- **Gợi ý câu hỏi tiếp theo:** Sau mỗi phản hồi, chatbot đề xuất 2–3 câu hỏi liên quan để người dùng tiếp tục khai thác.
- **Đánh giá chất lượng:** Người dùng có thể đánh giá phản hồi (thích/không thích) và để lại nhận xét, giúp cải thiện chất lượng hệ thống.
- **Cá nhân hóa:** Hệ thống ghi nhớ sở thích của người dùng (khu vực ưa thích, ngân sách, loại hình) và sử dụng chúng để cá nhân hóa phản hồi trong các phiên sau.

Nhóm chức năng chatbot đa tác tử

Đây là nhóm chức năng cốt lõi tạo nên sự khác biệt của hệ thống so với các nền tảng bất động sản truyền thống:

1. Phân loại ý định người dùng (Intent Routing):

- Hệ thống tự động phân tích câu hỏi tiếng Việt để xác định người dùng đang cần: tìm kiếm bất động sản, phân tích thị trường, tư vấn pháp lý, hay tư vấn đầu tư.
- **Hai cơ chế routing:** (1) Keyword-based – sử dụng regex và từ khóa tiếng Việt không dấu để nhận diện ý định, hoạt động không cần API key; (2) Gemini-based – sử dụng Google Gemini 2.0 Flash để phân loại với độ chính xác cao hơn, tự động kích hoạt khi có GEMINI_API_KEY.
- Router có thể chọn nhiều agent cùng lúc nếu câu hỏi liên quan đến nhiều lĩnh vực (ví dụ: “căn hộ Quận 7 dưới 3 tỷ, thủ tục pháp lý thế nào” sẽ kích hoạt cả Property Search và Legal Advisor).

2. Tìm kiếm bất động sản thông minh (Property Search):

- Tự động trích xuất bộ lọc có cấu trúc từ câu hỏi tiếng Việt: loại giao dịch (mua/thuê), loại hình (căn hộ, nhà,...), thành phố, quận, khoảng giá, diện tích. Ví dụ: “tìm

căn hộ Quận 7 dưới 5 tỷ, 2 phòng ngủ” được parse thành {listing_type: sale, property_type: apartment, district: Quận 7, max_price: 5, bedrooms: 2}.

- Thực hiện hybrid search kết hợp SQL filtering và pgvector semantic search. Kết quả được xếp hạng lại qua Cohere Rerank (nếu có API key) và trả về kèm giải thích lý do từng bất động sản phù hợp.

3. Phân tích thị trường (Market Analysis):

- Cung cấp số liệu thống kê thị trường theo thời gian thực: giá trung bình, giá/m², số lượng tin đăng, xu hướng biến động theo khu vực và loại hình.
- So sánh giữa các khu vực: giá trung bình tại Quận 7 so với Quận 2, giá căn hộ so với nhà riêng trong cùng khu vực.

4. Tư vấn pháp lý (Legal Advisor):

- Cung cấp thông tin về các vấn đề pháp lý thường gặp trong giao dịch bất động sản: sổ đỏ/sổ hồng, thủ tục sang tên, công chứng hợp đồng, các loại thuế và phí, quy hoạch, điều kiện vay ngân hàng.
- Thông tin được truy xuất từ Legal Knowledge Base – kho tài liệu pháp lý được xử lý và lập chỉ mục định kỳ hàng tháng.

5. Tư vấn đầu tư (Investment Advisor):

- Phân tích tiềm năng đầu tư dựa trên các yếu tố: vị trí, giá, xu hướng thị trường, tiện ích xung quanh, quy hoạch hạ tầng.
- Đánh giá sơ bộ về thanh khoản, khả năng cho thuê lại, tỷ suất sinh lời kỳ vọng và biên an toàn tài chính.

6. Tổng hợp và phản hồi (Synthesis):

- Khi nhiều agent cùng được kích hoạt, orchestrator gọi chúng song song và tổng hợp kết quả thành một phản hồi duy nhất, mạch lạc, tránh trùng lặp.
- Mỗi phản hồi đều được kiểm tra an toàn (safety validation) trước khi gửi đến người dùng.

7. Ghi nhớ và cá nhân hóa (Memory System):

- Chatbot tự động trích xuất sở thích người dùng từ hội thoại (ví dụ: “Tôi thích căn hộ ở Quận 7, ngân sách khoảng 3 tỷ”) và lưu dưới dạng MemoryProposal.

- Các sở thích có độ tin cậy cao ($\geq 80\%$) được tự động áp dụng. Các sở thích khác cần người dùng xác nhận.
- Sở thích đã xác nhận được sử dụng để cá nhân hóa phản hồi trong các phiên chat sau.

Nhóm chức năng quản trị và tự động hóa

1. Thu thập dữ liệu tự động:

- **Crawl tin đăng hàng ngày:** Tự động thu thập tin bán và cho thuê mới từ batdongsan.com.vn vào 02:00 giờ Hồ Chí Minh. Cơ chế watermark đảm bảo chỉ crawl dữ liệu mới, tránh trùng lặp.
- **Crawl dự án hàng tuần:** Thu thập thông tin dự án bất động sản (chủ đầu tư, quy mô, vị trí, tiện ích) vào Chủ nhật hàng tuần.
- **Crawl tin tức hàng tuần:** Thu thập bài viết phân tích thị trường, tin tức bất động sản.
- **Cập nhật kiến thức pháp lý hàng tháng:** Xử lý lại toàn bộ tài liệu pháp lý, bao gồm cả HTML và PDF.

2. Xử lý dữ liệu (ETL Pipeline):

- **Làm sạch:** Chuẩn hóa giá (tỷ, triệu, triệu/tháng), diện tích (m^2), phân loại loại hình bất động sản, chuẩn hóa địa chỉ.
- **Làm giàu:** Geocoding – chuyển địa chỉ thành tọa độ (latitude, longitude) qua Nominatim hoặc Goong API. Intent tagging – tự động gán nhãn nhu cầu (“gần trường học”, “view đẹp”, “an ninh”,...) dựa trên nội dung mô tả.
- **Chunking:** Chia văn bản thành các đoạn ngữ nghĩa (chunks) với 4 loại: overview (tổng quan), description (mô tả chi tiết), location (vị trí), intent_tags (nhu cầu). Mỗi chunk được thiết kế để có thể đứng độc lập về mặt ngữ nghĩa.
- **Embedding:** Tạo vector embedding 1024 chiều cho từng chunk sử dụng mô hình BGE-M3 (BAAI/bge-m3) với batch size 16 và retry policy 3 lần.
- **Nạp dữ liệu:** Upsert vào PostgreSQL: bảng listings cho dữ liệu quan hệ, bảng chunks cho dữ liệu vector. Sử dụng cơ chế batch processing để tối ưu hiệu năng.

3. Quản trị và giám sát hệ thống:

- **Admin Dashboard:** Giao diện quản trị với các tab: Pipeline Readiness (trạng thái các nguồn dữ liệu), Agent Traces (lịch sử xử lý của agent với latency và status), Chat Feedback (phản hồi người dùng), Memory Proposals (các đề xuất đang chờ xác nhận).
- **Observability:** Hệ thống tracing toàn diện cho phép theo dõi toàn bộ luồng xử lý của từng request chatbot: intent, agents được chọn, thời gian xử lý từng bước, kết quả retrieval, LLM calls, errors.
- **Monitoring:** Prometheus metrics endpoint cung cấp các chỉ số: số lượng request chat, thời gian phản hồi, số lượng pipeline runs, tỷ lệ lỗi.
- **Alerting:** Cơ chế cảnh báo qua Slack và email khi pipeline thất bại hoặc hiệu năng bất thường.

2.1.2. Yêu cầu phi chức năng

Bảng 2.1 tổng hợp các yêu cầu phi chức năng của hệ thống.

Tiêu chí	Yêu cầu chi tiết
Hiệu năng	• API listings phản hồi < 500ms với bộ lọc cơ bản, < 1000ms với bộ lọc phức tạp • Chatbot pipeline hoàn thành < 5s cho truy vấn thông thường, < 15s cho truy vấn phức tạp có multi-agent • Trang web tải trong < 3s (First Contentful Paint) trên kết nối 4G
Khả năng mở rộng	• Kiến trúc microservices: mỗi service có thể scale độc lập • Database connection pool: 20 connections + 10 overflow • Redis caching giảm tải database cho truy vấn lặp lại • Airflow DAGs hỗ trợ parallel task execution

Bảo mật	• Xác thực JWT với HS256, token hết hạn sau 24h • Mật khẩu hash bằng bcrypt với salt • Chống SQL injection qua SQLAlchemy ORM (parameterized queries) • Chống XSS qua Next.js auto-escaping • CORS whitelist qua biến môi trường CORS_ORIGINS • Internal API giữa backend và agent service bảo vệ bằng internal key
Độ tin cậy	• Fallback mechanism 3 cấp: multi-agent pipeline → simple RAG → thông báo an toàn • Retry policy cho embedding: 3 lần với exponential backoff • Retry policy cho Airflow tasks: 3 lần, 5–30 phút • Health check endpoints cho tất cả services • Database health check trước khi khởi động service

Khả năng bảo trì	• Mã nguồn phân chia module rõ ràng theo domain • Docstring tiếng Anh cho tất cả hàm/class • Type hints đầy đủ (Python) và TypeScript (frontend) • Hơn 55 file test bao phủ toàn bộ module • ESLint cho frontend, compileall cho Python
Tương thích ngôn ngữ	• Giao diện người dùng: 100% tiếng Việt • Chatbot: hiểu và phản hồi bằng tiếng Việt • Embedding: BGE-M3 tối ưu cho hơn 100 ngôn ngữ bao gồm tiếng Việt • URL slugs: tiếng Việt không dấu


Bảng 2.1: Các yêu cầu phi chức năng của hệ thống

2.2. Thiết kế kiến trúc hệ thống

2.2.1. Kiến trúc tổng thể

Hệ thống được thiết kế theo kiến trúc microservices, trong đó mỗi service đảm nhận một trách nhiệm riêng biệt và giao tiếp với nhau qua REST API. Hình 2.1 thể hiện kiến trúc tổng thể của toàn bộ hệ thống với 5 tầng chính.

KIẾN TRÚC HỆ THỐNG REAL ESTATE CHATBOT PLATFORM



Tầng Người dùng (User Layer)

Người dùng tương tác với hệ thống qua trình duyệt web (desktop và mobile). Có hai nhóm người dùng chính:

- **Người dùng cuối:** Truy cập các trang duyệt bất động sản, xem thống kê thị trường và tương tác với chatbot tư vấn.
- **Quản trị viên:** Truy cập admin dashboard để giám sát pipeline, theo dõi agent traces và quản lý phản hồi người dùng.

Tầng Frontend – Next.js (Port 3000)

Frontend được xây dựng với Next.js 16 và React 19, sử dụng App Router để tổ chức các trang. Các đặc điểm thiết kế chính:

- **Server-Side Rendering (SSR):** Các trang danh sách và chi tiết bất động sản được render phía server, đảm bảo SEO và thời gian tải nhanh.
- **React Server Components (RSC):** Mặc định sử dụng Server Components để giảm JavaScript gửi về client.
- **Tailwind CSS v4:** Utility-first CSS framework đảm bảo giao diện nhất quán, responsive trên mọi thiết bị.
- **Typed API Client:** File `lib/api.ts` cung cấp các hàm gọi backend với TypeScript type safety, tự động gắn JWT token vào header.
- **Chat Widget:** Thành phần nổi (floating) luôn hiển thị, cho phép người dùng tương tác với chatbot ở bất kỳ trang nào.

Frontend chỉ giao tiếp trực tiếp với Backend API qua REST. Frontend không được phép gọi trực tiếp Agent Service – đây là nguyên tắc thiết kế quan trọng để đảm bảo bảo mật và khả năng bảo trì.

Tầng Backend API – FastAPI (Port 8000)

Backend API là cổng giao tiếp chính của toàn bộ hệ thống, đảm nhận mọi request từ frontend. Backend được tổ chức thành 4 lớp:

1. **Lớp Models (ORM):** Định nghĩa 14+ bảng dữ liệu với SQLAlchemy 2.0 async. Mỗi model ánh xạ trực tiếp đến một bảng trong PostgreSQL. Các mối quan hệ (relationships)

được định nghĩa rõ ràng: Listing → Chunk (polymorphic), User → ChatSession → ChatMessage, User → UserPreference.

2. **Lớp Schemas (Pydantic):** Định nghĩa contract cho request/response. Pydantic v2 tự động validate dữ liệu đầu vào, sinh JSON Schema và tài liệu OpenAPI. Các schema được thiết kế tách biệt cho từng nghiệp vụ: listing (ListingCard, ListingDetail, PaginatedResponse), chat (ChatMessageRequest, ChatMessageResponse), auth (UserRegisterRequest, TokenResponse), admin (TraceSummary, PipelineReadinessItem).
3. **Lớp Bộ định tuyến (API Endpoints):** Xử lý yêu cầu HTTP, gọi dịch vụ tương ứng và trả về phản hồi. Máy chủ có 8 mô-đun định tuyến, mỗi mô-đun phụ trách một nhóm chức năng: bất động sản, thị trường, trò chuyện, xác thực, sở thích, ghi nhớ, quản trị và chỉ số. Các bộ định tuyến sử dụng tiêu phụ thuộc để nhận phiên cơ sở dữ liệu và xác thực người dùng.
4. **Lớp Services (Business Logic):** Chứa toàn bộ logic nghiệp vụ, được chia thành 3 nhóm chính:
 - **Chatbot Pipeline (services/chatbot/):** Pipeline multi-agent nội bộ với router (phân loại ý định), orchestrator (điều phối và tổng hợp), 4 agent chuyên biệt, context builder (xây dựng ngữ cảnh hội thoại), memory manager (quản lý ghi nhớ người dùng).
 - **RAG Services (services/rag/):** Các dịch vụ truy xuất thông tin: hybrid search (kết hợp SQL + vector + rerank + cache), embeddings (BGE-M3 wrapper với batch processing và retry), cache (Redis caching cho embedding và kết quả tìm kiếm).
 - **Agent Service Client (services/agent_service/):** HTTP client giao tiếp với Agent Service qua internal API, sử dụng internal key authentication.

Tầng Agent Service – FastAPI + LangGraph (Port 8100)

Agent Service là dịch vụ vi mô riêng biệt, được thiết kế để xử lý các tác vụ trí tuệ nhân tạo phức tạp mà không ảnh hưởng đến hiệu năng của Máy chủ Dịch vụ chính. Dịch vụ này sử dụng LangGraph để điều phối quy trình đa tác tử qua đồ thị trạng thái 14 nút, tổ chức thành bốn nhóm chức năng.

Nhóm chuẩn bị và định tuyến gồm năm nút. Nút xây dựng ngữ cảnh tổng hợp lịch sử trò chuyện và sở thích người dùng để đưa vào lời nhắc cho tất cả các bước sau. Nút kiểm tra trạng thái sẵn sàng đánh giá tính khả dụng của từng nguồn dữ liệu (bất động sản, dự

án, bài viết, kho kiến thức pháp lý) và điều chỉnh chiến lược truy xuất khi có nguồn chưa sẵn sàng. Nút định tuyến phân loại ý định và chọn danh sách tác tử cần kích hoạt, sử dụng Gemini 2.0 Flash với lời nhắc thiết kế riêng cho lĩnh vực bất động sản tiếng Việt. Nút làm rõ phát hiện các truy vấn thiếu thông tin và tạo câu hỏi làm rõ trước khi tiếp tục xử lý. Nút hiểu truy vấn phân tích sâu ngữ nghĩa để trích xuất thực thể, ràng buộc và ngữ cảnh ẩn.

Nhóm truy xuất và xử lý chuyên biệt gồm ba nút. Nút lập kế hoạch truy xuất xác định nguồn dữ liệu cần truy vấn, bộ lọc áp dụng và độ ưu tiên, kết quả được cấu trúc thành danh sách nhiệm vụ truy xuất. Nút tác tử chuyên biệt thực thi đồng thời các tác tử được chọn: tìm kiếm bất động sản (thực hiện tìm kiếm lai và trích xuất bộ lọc), phân tích thị trường (truy vấn thống kê và xu hướng), tư vấn pháp lý (tìm trong kho kiến thức pháp lý) và tư vấn đầu tư (phân tích tiềm năng sinh lời). Nút mô hình đầu tư tính toán các chỉ số tài chính cho bất động sản được tư vấn đầu tư.

Nhóm tổng hợp và kiểm tra gồm hai nút. Nút tổng hợp kết hợp kết quả từ các tác tử thành phản hồi mạch lạc, ưu tiên thông tin có độ tin cậy cao và loại bỏ trùng lặp. Nút kiểm tra an toàn đánh giá phản hồi theo bốn tiêu chí: tính có căn cứ (dựa trên nguồn dữ liệu thực), tính hữu ích, an toàn (không đưa ra khẳng định pháp lý hay tài chính tuyệt đối) và chất lượng trích dẫn.

Nhóm phản ứng và cải thiện gồm ba nút. Nút điều khiển phản ứng quyết định có cần truy xuất thêm hoặc chạy lại tác tử khi phát hiện phản hồi thiếu bằng chứng. Nút truy xuất phản ứng thực hiện truy vấn bổ sung theo yêu cầu. Nút đánh giá hội đồng cho phép các tác tử xem xét chéo kết quả của nhau. Cuối cùng, nút đề xuất ghi nhớ trích xuất sở thích tiềm năng của người dùng từ nội dung hội thoại và tạo đề xuất để lưu vào hệ thống.

Cơ chế đánh giá chất lượng:

Sau mỗi phản hồi, hệ thống có thể kích hoạt bộ đánh giá tự động sử dụng Gemini để chấm điểm theo năm tiêu chí (thang 0,0–1,0): tính có căn cứ, tính hữu ích, chất lượng trích dẫn, an toàn và tính đầy đủ của vết xử lý. Kết quả đánh giá được lưu vào bảng vết tác tử để phân tích và cải thiện hệ thống.

Tương tác giữa Máy chủ Dịch vụ và Dịch vụ Tác tử:

Máy chủ Dịch vụ gọi Dịch vụ Tác tử qua trình khách HTTP với xác thực bằng khóa nội bộ. Dịch vụ Tác tử nhận yêu cầu chứa câu hỏi, mã phiên, mã người dùng và lịch sử hội thoại, trả về phản hồi cuối cùng, danh sách tác tử đã sử dụng, nguồn tham khảo, hành động gợi ý và vết xử lý đầy đủ. Máy chủ Dịch vụ lưu kết quả vào các bảng tin nhắn, vết tác tử và bảng liên quan trước khi trả về giao diện người dùng. Khi Dịch vụ Tác tử không được kích hoạt hoặc không khả dụng, Máy chủ Dịch vụ tự động chuyển sang đường ống nội bộ.

Tầng Dữ liệu

PostgreSQL 16 với tìm kiếm véc-tơ (công 5432):

PostgreSQL được chọn làm cơ sở dữ liệu chính nhờ khả năng lưu trữ đồng thời dữ liệu quan hệ và dữ liệu véc-tơ thông qua phần mở rộng pgvector. Điều này giúp giảm độ phức tạp vận hành so với việc sử dụng hai hệ quản trị riêng biệt.

Dữ liệu quan hệ gồm 14 bảng: bất động sản (30 trường), người dùng, phiên và tin nhắn trò chuyện, dự án, bài viết, cùng các bảng giám sát (vết tác tử, các bước vết, lời gọi mô hình ngôn ngữ, sự kiện truy xuất, lần chạy đường ống, trạng thái nguồn, sở thích người dùng, đề xuất ghi nhớ, phản hồi đánh giá).

Dữ liệu véc-tơ được lưu trong bảng đoạn văn bản với cột véc-tơ 1024 chiều, phục vụ tìm kiếm ngữ nghĩa. Chỉ mục HNSW với tham số $m = 16$ và $ef_construction = 64$ đảm bảo tốc độ tìm kiếm k lân cận gần nhất nhanh trên tập dữ liệu lớn. Thiết kế đa hình cho phép một bảng đoạn văn bản duy nhất phục vụ nhiều loại dữ liệu nguồn (bất động sản, dự án, bài viết) thông qua cặp cột loại nguồn và mã nguồn.

Redis 7 (công 6379):

Redis được sử dụng làm bộ nhớ đệm ở hai cấp độ: bộ nhớ đệm véc-tơ đặc trưng (lưu véc-tơ của câu truy vấn, tránh mã hóa lại) và bộ nhớ đệm kết quả tìm kiếm (lưu kết quả tìm kiếm lai cho truy vấn lặp lại).

- **Embedding Cache:** Lưu vector embedding của câu truy vấn, tránh phải encode lại. Key có dạng `embedding:{provider}:{model}:{dim}:{hash}`, cho phép cache hoạt động chính xác ngay cả khi thay đổi model.
- **Search Result Cache:** Lưu kết quả hybrid search cho các truy vấn lặp lại, giảm tải đáng kể cho PostgreSQL.

Tầng Data Pipeline & Tự động hóa

Đây là tầng vận hành ngầm, đảm bảo dữ liệu luôn được cập nhật và sẵn sàng cho các tầng phía trên.

Crawlers (Playwright + Stealth):

Hệ thống crawler được tổ chức thành 5 module, mỗi module phụ trách một loại nội dung:

- `crawler/core/`: Các thành phần dùng chung – CSV writer (với dedup), base parser, listing detail parser.
- `crawler/sale/`: Crawl tin bán (2 bước: crawl URLs → crawl details).

- `crawler/rent/`: Crawl tin cho thuê (tương tự).
- `crawler/projects/`: Crawl thông tin dự án bất động sản.
- `crawler/news/`: Crawl tin tức và bài viết phân tích.

Crawler sử dụng Playwright với chế độ stealth để tránh bị phát hiện, hỗ trợ 4 workers chạy song song để tăng tốc độ. Dữ liệu được ghi ra file CSV UTF-8 BOM và được deduplicate dựa trên `product_id`.

Data Pipeline (ETL + Embedding):

Pipeline xử lý dữ liệu gồm 5 bước chính, được thiết kế để chạy độc lập hoặc theo chuỗi:

1. **Clean (`clean.py`):** Parse và chuẩn hóa dữ liệu thô từ CSV. Các công việc chính: tách giá trị số từ text giá (“4,68 tỷ” → 4.68, unit: billion), tách diện tích (“75 m²” → 75), phân loại loại hình bất động sản, chuẩn hóa địa chỉ.
2. **Enrich (`enrich.py`):** Làm giàu dữ liệu với hai tác vụ: (1) Geocoding – gọi Nominatim/Goong API để chuyển địa chỉ text thành tọa độ (latitude, longitude); (2) Intent Tagging – phân tích nội dung mô tả để gán nhãn nhu cầu (“gần trường học”, “view đẹp”, “an ninh”, “pháp lý rõ”,...).
3. **Chunk (`chunk.py`):** Chia văn bản thành các đoạn ngữ nghĩa. Mỗi listing được chunk thành 4 loại: overview (tổng quan – tiêu đề, giá, diện tích, khu vực, pháp lý, nội thất), description (mô tả chi tiết), location (địa chỉ, quận, thành phố), intent_tags (nhu cầu phù hợp). Thiết kế này đảm bảo mỗi chunk có thể đứng độc lập và được truy xuất chính xác theo ngữ cảnh.
4. **Embed (`embed.py`):** Tạo vector embedding 1024 chiều cho từng chunk bằng mô hình BGE-M3. Sử dụng BGEmbedder class với batch size 16, retry 3 lần với exponential backoff, chạy async qua `asyncio.to_thread()` để không chặn event loop.
5. **Load (`load_db.py` + `ingestors/`):** Upsert dữ liệu đã xử lý vào PostgreSQL. Các ingestor module chuyên biệt cho từng loại dữ liệu (listings, projects, news, legal_kb) đảm bảo logic nạp phù hợp với schema của từng bảng.

Apache Airflow Scheduler:

Toàn bộ pipeline được lập lịch và giám sát bởi Apache Airflow với 4 DAGs:

- **daily_listings_dag (02:00 HCM):** Quy trình đầy đủ cho tin đăng: `crawl_sale_urls` → `crawl_sale_details` → `ingest_sale` (chạy song song với `crawl_rent_urls` → `crawl_rent_details`)

→ ingest_rent) → mark_active → chunk_and_embed. Sử dụng watermark để chỉ xử lý dữ liệu mới.

- **weekly_projects_dag (Chủ nhật 03:00):** Crawl và nạp dự án bất động sản.
- **weekly_news_dag (Chủ nhật 04:00):** Crawl và nạp tin tức thị trường.
- **monthly_legal_kb_dag (Ngày 1, 05:00):** Xử lý lại toàn bộ tài liệu pháp lý từ data/knowledge

Mỗi DAG được cấu hình retry 3 lần với exponential backoff (5–30 phút), cảnh báo qua Slack và email khi thất bại, và ghi metrics vào bảng pipeline_runs.

2.3. Thiết kế cơ sở dữ liệu

2.3.1. Mô hình quan hệ

Hệ thống sử dụng PostgreSQL 16 với extension pgvector. Mô hình dữ liệu được thiết kế xoay quanh 3 nhóm bảng chính:

Nhóm bảng nghiệp vụ (Business Tables)

Đây là nhóm bảng lưu trữ dữ liệu cốt lõi của hệ thống:

- **listings – Bảng bất động sản:** Bảng quan trọng nhất với hơn 30 trường dữ liệu, lưu toàn bộ thông tin của một tin đăng. Khóa chính là id (INTEGER, auto-increment). Mỗi listing có product_id duy nhất từ nguồn crawl để deduplicate. Các chỉ mục (indexes) được tạo trên các trường thường xuyên dùng trong bộ lọc: listing_type, city, district, property_type, price, area, bedrooms, post_date, is_active.
- **projects – Bảng dự án:** Lưu thông tin dự án bất động sản: tên, chủ đầu tư, vị trí, quy mô (tổng số căn), khoảng giá, khoảng diện tích, trạng thái (sắp mở bán, đang bán, đã bàn giao), loại hình, tiện ích (mảng ARRAY), mô tả.
- **articles – Bảng bài viết:** Lưu tin tức và kiến thức pháp lý: tiêu đề, nội dung, danh mục, nguồn, ngày đăng, URL gốc, metadata.
- **users – Bảng người dùng:** Lưu thông tin tài khoản: email (unique), mật khẩu đã hash, họ tên, số điện thoại, avatar, trạng thái hoạt động, quyền (admin/superuser).

Nhóm bảng hội thoại (Chat Tables)

- **chat_sessions – Phiên hội thoại:** Mỗi phiên có id UUID, liên kết đến user (có thể NULL cho anonymous), tiêu đề tự động sinh từ tin nhắn đầu tiên.

- **chat_messages – Tin nhắn:** Mỗi tin nhắn thuộc về một session, có role (user/assistant/system), nội dung, agent đã xử lý, và metadata JSONB (chứa sources, citations, search context).

Nhóm bảng vector và tìm kiếm (Vector & Retrieval Tables)

- **chunks – Đoạn văn bản đã embedding:** Thiết kế polymorphic với parent_type (listing/project/area) và parent_id. Mỗi chunk có chunk_type xác định loại nội dung (overview/description/location/introduction). text là nội dung văn bản, embedding là VECTOR(1024). HNSW index trên cột embedding với cosine distance operator đảm bảo tìm kiếm k-NN nhanh.

Nhóm bảng observability & vận hành (Observability Tables)

- **agent_traces:** Lưu vết xử lý của mỗi request chatbot: intent, danh sách agents đã dùng, trace_summary, full_trace (JSONB), latency, status, graph_version, prompt_version, model_name.
- **agent_trace_steps:** Chi tiết từng bước trong trace: step_name, status, latency, input/output JSON.
- **agent_llm_calls:** Log mỗi lần gọi LLM: node_name, model_name, latency, token estimates.
- **agent_retrieval_events:** Log mỗi sự kiện truy xuất.
- **pipeline_runs:** Log mỗi lần chạy Airflow DAG: dag_id, run_id, status, thời gian, metrics.
- **source_readiness:** Trạng thái sẵn sàng của từng nguồn dữ liệu.
- **user_preferences:** Sở thích người dùng dạng key-value JSONB.
- **memory_proposals:** Đề xuất sở thích từ agent.
- **chat_feedback:** Phản hồi của người dùng về chất lượng chat.

2.3.2. Chiến lược indexing

- **Index cho listings:** Các B-tree index trên listing_type, city, district, property_type, price, area, bedrooms, post_date, is_active giúp tối ưu các truy vấn lọc và sắp xếp phổ biến. Composite index nhằm được PostgreSQL sử dụng khi nhiều điều kiện AND.
- **Index cho chunks:** HNSW index trên cột embedding với vector_cosine_ops. Đây là loại index xấp xỉ (approximate nearest neighbor) cho phép tìm kiếm k-NN trong

không gian 1024 chiều với độ phức tạp $O(\log N)$ thay vì $O(N)$ của full scan. Tham số $m = 16$ (số kết nối mỗi node trong đồ thị HNSW) và $ef_construction = 64$ (kích thước dynamic candidate list) được chọn sau thử nghiệm để cân bằng giữa tốc độ build index và chất lượng tìm kiếm.

- **Index cho polymorphic queries:** Composite index trên (parent_type, parent_id) của bảng chunks giúp truy vấn nhanh tất cả chunks thuộc về một listing/project/article.

2.4. Thiết kế giao diện người dùng

CHƯƠNG 3. TRIỂN KHAI VÀ KIỂM THỬ

Chương này trình bày chi tiết quá trình triển khai hệ thống lên môi trường vận hành và chiến lược kiểm thử toàn diện được áp dụng trong đề án. Phần đầu mô tả kiến trúc triển khai với Docker Compose, cấu hình từng dịch vụ, quy trình xây dựng và chạy hệ thống. Phần tiếp theo trình bày chiến lược kiểm thử đa tầng: từ kiểm thử đơn vị, kiểm thử tích hợp đến kiểm thử hệ thống và kiểm thử chấp nhận. Cuối cùng, chương tổng hợp kết quả kiểm thử, các vấn đề đã phát hiện và hướng khắc phục.

3.1. Triển khai hệ thống với Docker

3.1.1. Kiến trúc triển khai

Hệ thống được triển khai theo mô hình container hóa với Docker Compose, bao gồm 5 service chính hoạt động trong cùng một mạng nội bộ (internal network). Mỗi service được đóng gói trong một Docker image riêng, đảm bảo tính nhất quán giữa môi trường phát triển và môi trường vận hành. Hình 3.1 mô tả tổng quan kiến trúc triển khai.

Docker Compose – Nền tảng Tư vấn Bất động sản				
Giao diện	Máy chủ	Dịch vụ Tác tử	PostgreSQL	Redis
Next.js 16 Cổng 3000	FastAPI Cổng 8000	FastAPI + LangGraph Cổng 8100	16 + pgvector Cổng 5432	7 Alpine Cổng 6379
Mạng nội bộ: realestate_network				
Ổ đĩa: pgdata, redisdata				

Hình 3.1: Kiến trúc triển khai Docker Compose

3.1.2. Cấu hình Docker Compose

Toàn bộ hệ thống được định nghĩa trong file `docker-compose.yml` tại thư mục gốc của dự án. Cấu hình này đảm bảo:

- **Khởi động có thứ tự:** Các dịch vụ được khởi động theo đúng thứ tự phụ thuộc. PostgreSQL và Redis khởi động trước, sau đó đến Dịch vụ Tác tử, rồi Máy chủ Dịch vụ, và cuối cùng là Giao diện người dùng. Cơ chế phụ thuộc kết hợp với kiểm tra trạng thái đảm bảo dịch vụ chỉ khởi động khi các dịch vụ phụ thuộc đã sẵn sàng.
- **Kiểm tra trạng thái:** Mỗi dịch vụ được cấu hình kiểm tra trạng thái riêng:
 - **PostgreSQL:** `pg_isready -U admin -d realestate` – kiểm tra định kỳ mỗi 10 giây, tối đa 5 lần thử.

- **Redis:** `redis-cli ping` – kiểm tra định kỳ mỗi 10 giây, tối đa 5 lần thử.
- **Dịch vụ Tác tử:** Gọi `/internal/agent/health` với khóa nội bộ – kiểm tra mỗi 10 giây, tối đa 12 lần thử, có 30 giây khởi động ban đầu.
- **Quản lý dữ liệu bền vững:** Hai ổ đĩa Docker được tạo để lưu trữ dữ liệu bền vững: `pgdata` lưu toàn bộ dữ liệu PostgreSQL (bao gồm cả dữ liệu quan hệ và chỉ mục véc-tơ) và `redisdata` lưu dữ liệu bộ nhớ đệm của Redis. Các ổ đĩa này tồn tại độc lập với vòng đời vùng chứa, đảm bảo dữ liệu không bị mất khi vùng chứa được tạo lại.
- **Biến môi trường:** Tất cả cấu hình nhạy cảm được truyền qua biến môi trường từ tệp `.env`, không được gán cứng trong tệp cấu hình Docker.

3.1.3. Cấu hình chi tiết từng dịch vụ

PostgreSQL + pgvector

```
postgres:
  image: pgvector/pgvector:pg16
  container_name: realestate_postgres
  environment:
    POSTGRES_DB: realestate
    POSTGRES_USER: admin
    POSTGRES_PASSWORD: ${POSTGRES_PASSWORD}
  volumes:
    - pgdata:/var/lib/postgresql/data
  ports:
    - "5432:5432"
```

PostgreSQL được triển khai với image `pgvector/pgvector:pg16`, tích hợp sẵn extension `pgvector` cho phép lưu trữ và tìm kiếm vector embedding. Database mặc định được đặt tên là `realestate` với user `admin`. Extension `pgvector` được tự động kích hoạt thông qua SQLAlchemy trong quá trình khởi tạo schema (hàm `init_db()` trong `backend/app/database.py`).

Redis

```
redis:
  image: redis:7-alpine
```

```
container_name: realestate_redis
ports:
  - "6379:6379"
volumes:
  - redisdata:/data
```

Redis sử dụng image Alpine nhẹ (chỉ khoảng 30MB), phù hợp với môi trường container hóa. Redis đảm nhận hai vai trò: caching embedding vector và caching kết quả hybrid search. Dữ liệu cache được lưu bền vững qua volume `redisdata`.

Agent Service

```
agent-service:
  build:
    context: .
    dockerfile: agent_service/Dockerfile
  container_name: realestate_agent_service
  depends_on:
    postgres:
      condition: service_healthy
    redis:
      condition: service_healthy
  env_file: .env
  environment:
    DATABASE_URL: postgresql+asyncpg://admin:...@postgres:5432/realestate
    REDIS_URL: redis://redis:6379/0
    AGENT_INTERNAL_KEY: ${AGENT_INTERNAL_KEY}
    GEMINI_API_KEY: ${GEMINI_API_KEY}
    GEMINI_MODEL: gemini-2.0-flash
```

Dịch vụ Tác tử được xây dựng từ Dockerfile riêng trong thư mục `agent_service/`. Dockerfile dựa trên Python 3.12-slim, cài đặt các thư viện cần thiết (bao gồm LangGraph, sentence-transformers, httpx) và chạy ứng dụng qua Uvicorn trên cổng 8100. Biến môi trường `PYTHONPATH` được thiết lập để Dịch vụ Tác tử có thể nạp các mô-đun từ `backend/` (mô hình, cơ sở dữ liệu).

Điểm đặc biệt trong cấu hình Dịch vụ Tác tử là khoảng thời gian khởi động 30 giây trong kiểm tra trạng thái – khoảng thời gian này cho phép dịch vụ tải mô hình véc-tơ BGE-M3 (dung lượng khoảng 2GB) trước khi bắt đầu nhận yêu cầu kiểm tra.

Máy chủ Dịch vụ

```
backend:
  build:
    context: ./backend
    dockerfile: Dockerfile
  container_name: realestate_backend
  depends_on:
    postgres:
      condition: service_healthy
    redis:
      condition: service_healthy
    agent-service:
      condition: service_healthy
  env_file: .env
  environment:
    DATABASE_URL: postgresql+asyncpg://admin:...@postgres:5432/realestate
    REDIS_URL: redis://redis:6379/0
    AGENT_SERVICE_URL: http://agent-service:8100
    CHATBOT_AGENT_SERVICE_ENABLED: ${CHATBOT_AGENT_SERVICE_ENABLED:-false}
  volumes:
    - ./data:/app/data
```

Máy chủ Dịch vụ sử dụng Dockerfile trong thư mục `backend/`, dựa trên Python 3.12-slim với các gói phụ thuộc hệ thống cho `asyncpg` và `bcrypt`. Máy chủ chỉ khởi động sau khi cả PostgreSQL, Redis và Dịch vụ Tác tử đều đã sẵn sàng.

Biến `CHATBOT_AGENT_SERVICE_ENABLED` (mặc định: `false`) cho phép vận hành linh hoạt: khi bật, Máy chủ sẽ chuyển các yêu cầu chatbot sang Dịch vụ Tác tử để xử lý nâng cao; khi tắt, Máy chủ sử dụng đường ống nội bộ. Ổ đĩa `./data:/app/data` cho phép Máy chủ truy cập dữ liệu CSV và các tệp cấu hình từ máy chủ.

Giao diện người dùng

```
frontend:
  build:
    context: ./frontend
    dockerfile: Dockerfile
```

```
args:
  INTERNAL_API_URL: http://backend:8000
  NEXT_PUBLIC_API_URL: /api/v1
container_name: realestate_frontend
ports:
  - "3000:3000"
depends_on:
  - backend
```

Giao diện người dùng được xây dựng từ Dockerfile trong thư mục `frontend/`, sử dụng Node.js 22 Alpine. Quá trình xây dựng gồm hai bước: `npm ci` để cài đặt gói phụ thuộc và `npm run build` để tạo bản dựng sản xuất. Giao diện chạy ở chế độ sản xuất (`npm run start`) trên cổng 3000.

Hai tham số xây dựng quan trọng được truyền vào: `INTERNAL_API_URL` là địa chỉ nội bộ để Next.js gọi Máy chủ Dịch vụ phía máy chủ (dùng trong Thành phần Máy chủ và kết xuất phía máy chủ), và `NEXT_PUBLIC_API_URL` là địa chỉ công khai để phía trình duyệt gọi API.

3.1.4. Mạng nội bộ và giao tiếp giữa các dịch vụ

Các dịch vụ trong Docker Compose giao tiếp với nhau thông qua tên dịch vụ (DNS nội bộ của Docker). Cụ thể: Giao diện gọi Máy chủ qua `http://backend:8000` (cho kết xuất phía máy chủ) và qua `/api/v1` (cho phía trình duyệt, được Next.js chuyển tiếp); Máy chủ gọi Dịch vụ Tác tử qua `http://agent-service:8100/internal/agent/chat` với khóa nội bộ trong tiêu đề `X-Internal-Agent-Key`; Máy chủ kết nối đến PostgreSQL qua chuỗi kết nối bất đồng bộ; cả Máy chủ và Dịch vụ Tác tử đều kết nối đến Redis.

3.1.5. Quy trình triển khai

Chuẩn bị môi trường

Trước khi triển khai, cần chuẩn bị file `.env` với các biến môi trường bắt buộc:

```
# Database
POSTGRES_DB=realestate
POSTGRES_USER=admin
POSTGRES_PASSWORD=<mat_khau_manh>
DATABASE_URL=postgresql+asyncpg://admin:<password>@postgres:5432/realestate
```

```
# Redis
REDIS_URL=redis://redis:6379/0

# JWT
JWT_SECRET_KEY=<khoa_bi_mat_jwt>

# CORS
CORS_ORIGINS=http://localhost:3000

# AI/ML
GEMINI_API_KEY=<google_gemini_api_key>
COHERE_API_KEY=<cohere_api_key> # Optional

# Agent Service
AGENT_INTERNAL_KEY=<internal_key>
CHATBOT_AGENT_SERVICE_ENABLED=false # true để sử dụng Agent Service

# Frontend
NEXT_PUBLIC_API_URL=/api/v1
```

Xây dựng và khởi động

Quy trình triển khai đầy đủ gồm các bước sau:

1. Xây dựng ảnh:

```
docker-compose build
```

Lệnh này xây dựng ảnh Docker cho Máy chủ Dịch vụ, Dịch vụ Tác tử và Giao diện người dùng từ Dockerfile tương ứng. PostgreSQL và Redis sử dụng ảnh có sẵn từ Docker Hub.

2. Khởi động toàn bộ hệ thống:

```
docker-compose up -d
```

Docker Compose sẽ khởi động các dịch vụ theo thứ tự: PostgreSQL, Redis, Dịch vụ Tác tử, Máy chủ Dịch vụ, Giao diện người dùng. Tham số `-d` chạy ở chế độ nền.

3. Khởi động riêng các dịch vụ hạ tầng (cho phát triển):

```
docker-compose up -d postgres redis
```

Khi phát triển, chỉ cần chạy PostgreSQL và Redis qua Docker, còn Máy chủ và Giao diện chạy trực tiếp trên máy chủ để thuận tiện cho việc gỡ lỗi. Máy chủ: `uvicorn app.main:app --reload --port 8000`. Giao diện: `npm run dev`.

4. Khởi động lại một dịch vụ sau khi thay đổi mã nguồn:

```
docker-compose up -d --build backend
```

Lệnh này xây dựng lại ảnh và khởi động lại vùng chứa máy chủ.

5. Xem nhật ký:

```
docker-compose logs -f backend
```

Theo dõi nhật ký của một dịch vụ cụ thể.

6. Dừng hệ thống:

```
docker-compose down
```

Dừng và xóa tất cả vùng chứa. Dữ liệu trong ổ đĩa vẫn được giữ nguyên. Thêm `-v` để xóa cả ổ đĩa.

Kiểm tra trạng thái triển khai

Sau khi hệ thống khởi động, có thể kiểm tra trạng thái qua các điểm cuối kiểm tra:

- **Máy chủ Dịch vụ:** `GET http://localhost:8000/health` – trả về trạng thái cơ sở dữ liệu và Redis.

- **Dịch vụ Tác tử:** GET <http://localhost:8100/internal/agent/health> – yêu cầu khóa nội bộ.
- **Giao diện người dùng:** Mở trình duyệt tại <http://localhost:3000>.
- **Tài liệu API:** <http://localhost:8000/docs> – giao diện Swagger với đầy đủ lược đồ.

3.1.6. Nạp dữ liệu ban đầu

Sau khi hệ thống đã khởi động, cần nạp dữ liệu ban đầu vào PostgreSQL:

```
python -m data_pipeline.load_db
```

Quy trình nạp dữ liệu gồm các bước: đọc dữ liệu từ các tệp CSV trong thư mục dữ liệu; làm sạch và chuẩn hóa dữ liệu (phân tích giá, diện tích, phân loại); làm giàu dữ liệu (mã hóa địa lý, gán nhãn nhu cầu); chia văn bản thành các đoạn ngữ nghĩa với bốn loại cho mỗi bất động sản; tạo véc-tơ đặc trưng 1024 chiều bằng mô hình BGE-M3; nạp vào PostgreSQL qua các mô-đun chuyên biệt; và tạo chỉ mục HNSW trên cột véc-tơ của bảng đoạn văn bản.

3.2. Kiểm thử hệ thống

3.2.1. Chiến lược kiểm thử

Hệ thống được kiểm thử theo chiến lược đa tầng, từ thấp đến cao.

Tầng thứ nhất là kiểm thử đơn vị: kiểm tra từng hàm, lớp, mô-đun độc lập, sử dụng pytest với đối tượng giả để cô lập các phụ thuộc ngoại vi (cơ sở dữ liệu, API, hệ thống tệp). Đây là tầng kiểm thử có số lượng ca kiểm thử lớn nhất và chạy nhanh nhất.

Tầng thứ hai là kiểm thử tích hợp: kiểm tra sự tương tác giữa các mô-đun với nhau và với các dịch vụ bên ngoài (PostgreSQL, Redis, Gemini API), sử dụng cơ sở dữ liệu kiểm thử hoặc dịch vụ giả.

Tầng thứ ba là kiểm thử hợp đồng: kiểm tra tính tương thích giữa các dịch vụ qua hợp đồng API, đảm bảo thay đổi ở một dịch vụ không phá vỡ dịch vụ khác.

Tầng thứ tư là kiểm thử hệ thống: kiểm tra toàn bộ luồng hoạt động đầu cuối, từ giao diện người dùng đến máy chủ đến cơ sở dữ liệu, đảm bảo các chức năng hoạt động đúng như mong đợi.

Tầng thứ năm là kiểm thử chấp nhận: kiểm tra hệ thống đáp ứng các yêu cầu nghiệp vụ đã đề ra, được thực hiện thủ công với các kịch bản thực tế.

3.2.2. Công cụ và khung công tác kiểm thử

pytest là khung công tác kiểm thử chính cho toàn bộ mã nguồn Python (máy chủ, dịch vụ tác tử, đường ống dữ liệu, lập lịch), sử dụng các phần mở rộng: pytest-asyncio (hỗ trợ kiểm thử bất đồng bộ), pytest-cov (đo độ bao phủ). ESLint là công cụ phân tích tĩnh cho giao diện người dùng TypeScript, phát hiện lỗi cú pháp và vấn đề về phong cách mã nguồn. compileall là mô-đun chuẩn của Python dùng để kiểm tra cú pháp toàn bộ tệp mã nguồn, phát hiện lỗi nạp thư viện và lỗi cú pháp mà không cần chạy kiểm thử. Thư viện unittest.mock và pytest.monkeypatch được dùng để tạo đối tượng giả, giả lập các dịch vụ bên ngoài.

KẾT LUẬN

Kết quả đạt được

Sau quá trình nghiên cứu và triển khai, đồ án đã đạt được các kết quả chính sau đây.

Về xây dựng nền tảng: Đồ án đã xây dựng thành công một nền tảng web bất động sản hoàn chỉnh với giao diện người dùng hiện đại sử dụng Next.js 16 và React 19, máy chủ dịch vụ FastAPI. Nền tảng cung cấp đầy đủ các chức năng cho người dùng cuối: duyệt danh sách nhà đất bán và cho thuê, lọc đa tiêu chí (loại hình, khu vực, giá, diện tích, số phòng, hướng nhà), sắp xếp theo giá và diện tích, xem chi tiết bất động sản với ba mươi trường thông tin, bảng thống kê thị trường trực quan, cùng hệ thống xác thực người dùng qua mã thông báo và bảng điều khiển quản trị.

Về chatbot đa tác tử: Đồ án đã phát triển thành công chatbot đa tác tử với bốn tác tử chuyên biệt đảm nhận các vai trò tìm kiếm bất động sản, phân tích thị trường, tư vấn pháp lý và tư vấn đầu tư. Chatbot có khả năng hiểu ý định người dùng bằng tiếng Việt qua hai cơ chế định tuyến (dựa trên từ khóa và dựa trên mô hình ngôn ngữ lớn), điều phối đến tác tử phù hợp, truy xuất dữ liệu qua tìm kiếm lai (kết hợp truy vấn có cấu trúc, tìm kiếm véc-tơ qua chỉ mục HNSW, xếp hạng lại và bộ nhớ đệm Redis) và sinh phản hồi có trích dẫn nguồn rõ ràng.

Về kiến trúc hệ thống: Đồ án đã triển khai kiến trúc chatbot hai lớp với đường ống nội bộ xử lý nhanh cho người dùng cuối và Dịch vụ Tác tử chạy đồ thị trạng thái LangGraph riêng biệt cho suy luận đa bước nâng cao. Hệ thống tích hợp cơ chế ghi nhớ và sở thích người dùng để cá nhân hóa phản hồi. Toàn bộ hệ thống được thiết kế theo kiến trúc dịch vụ vi mô với năm dịch vụ độc lập trong Docker Compose, có khả năng mở rộng và triển khai dễ dàng trên nhiều môi trường.

Về đường ống dữ liệu: Đồ án đã xây dựng đường ống thu thập và xử lý dữ liệu tự động hoàn chỉnh từ batdongsan.com.vn. Quy trình bao gồm: thu thập dữ liệu bằng công cụ tự động hóa trình duyệt với cơ chế ẩn danh cho cả tin bán, tin cho thuê, dự án và tin tức; làm sạch và chuẩn hóa dữ liệu; làm giàu (mã hóa địa lý qua dịch vụ bản đồ, gán nhãn nhu cầu); chia đoạn ngữ nghĩa với bốn loại đoạn cho mỗi bất động sản; tạo véc-tơ đặc trưng 1024 chiều bằng mô hình BGE-M3; và nạp vào PostgreSQL với tìm kiếm véc-tơ qua các mô-đun chuyên biệt. Đường ống được lập lịch tự động qua Apache Airflow với bốn luồng công việc.

Về tìm kiếm: Đồ án đã triển khai hệ thống tìm kiếm lai hiệu quả, kết hợp giữa lọc có cấu trúc cho dữ liệu quan hệ và tìm kiếm véc-tơ với chỉ mục HNSW cho tìm kiếm ngữ

nghĩa, có xếp hạng lại qua mô hình chuyên dụng đa ngôn ngữ và bộ nhớ đệm qua Redis để cải thiện độ chính xác và tốc độ.

Về giám sát và chất lượng: Đồ án đã xây dựng hệ thống quan sát toàn diện với theo dõi vết tác tử (vết xử lý, các bước, lời gọi mô hình ngôn ngữ, sự kiện truy xuất), phản hồi đánh giá chất lượng, đề xuất ghi nhớ, giám sát trạng thái nguồn dữ liệu và điểm cuối chỉ số hệ thống. Bộ kiểm thử với hơn 60 tệp bao phủ toàn bộ các mô-đun: đường ống chatbot, dịch vụ tác tử, tìm kiếm lai, tạo sinh tăng cường truy xuất, đường ống dữ liệu, kho kiến thức pháp lý, thu thập dữ liệu, ghi nhớ/sở thích và quản trị.

Hạn chế

Bên cạnh những kết quả đạt được, đồ án vẫn còn một số hạn chế cần được khắc phục trong các phiên bản tiếp theo.

Thứ nhất, về nguồn dữ liệu, hệ thống hiện chỉ thu thập dữ liệu từ một nguồn duy nhất là batdongsan.com.vn. Điều này hạn chế độ phủ của dữ liệu, đặc biệt ở các khu vực mà nền tảng này chưa chiếm ưu thế. Việc tích hợp thêm các nguồn dữ liệu khác như alonhadat.com.vn, chotot.com sẽ giúp tăng đáng kể số lượng và chất lượng tin đăng.

Thứ hai, về chất lượng véc-tơ đặc trưng tiếng Việt, mô hình BGE-M3 tuy hỗ trợ tiếng Việt nhưng chưa được tối ưu riêng cho ngôn ngữ này. Các mô hình véc-tơ chuyên biệt cho tiếng Việt như PhoBERT, ViT5 cần được đánh giá và thử nghiệm để cải thiện độ chính xác của tìm kiếm ngữ nghĩa.

Thứ ba, về khả năng hội thoại của chatbot, hệ thống hiện tại vẫn gặp khó khăn với các câu hỏi phức tạp đòi hỏi suy luận qua nhiều bước hoặc tổng hợp thông tin từ nhiều nguồn khác nhau. Cơ chế ghi nhớ người dùng còn đơn giản, chưa hỗ trợ ghi nhớ ngữ cảnh dài hạn qua nhiều phiên.

Thứ tư, về giao diện người dùng, bảng điều khiển quản trị và các trang thống kê thị trường còn ở mức cơ bản, chưa có nhiều biểu đồ tương tác và khả năng lọc sâu. Trải nghiệm trên thiết bị di động cần được cải thiện thêm.

Thứ năm, về vận hành, hệ thống chưa được triển khai thực tế trên môi trường sản xuất với tên miền công cộng, chứng chỉ bảo mật và cân bằng tải. Khả năng chịu lỗi và phục hồi của hệ thống chưa được kiểm thử đầy đủ dưới tải cao.

Thứ sáu, về kiểm thử, mặc dù đã có hơn 60 tệp kiểm thử nhưng độ bao phủ mã nguồn còn chưa đồng đều giữa các mô-đun. Các bài kiểm thử đầu cuối cho luồng chatbot hoàn chỉnh còn hạn chế do phụ thuộc vào API bên ngoài.

Hướng phát triển

Từ những hạn chế đã nêu, đề án đề xuất các hướng phát triển trong tương lai.

Về dữ liệu, cần mở rộng thu thập từ nhiều nguồn bất động sản khác nhau, bổ sung dữ liệu về quy hoạch đô thị, hạ tầng giao thông và tiện ích xung quanh (trường học, bệnh viện, trung tâm thương mại) để làm giàu thông tin cho mỗi bất động sản.

Về chatbot, cần nâng cấp lên các mô hình ngôn ngữ mới hơn, hỗ trợ suy luận đa bước tốt hơn và xử lý ngữ cảnh dài. Tích hợp thêm tác tử chuyên biệt mới như tác tử so sánh bất động sản, tác tử dự báo giá, tác tử tư vấn vay ngân hàng. Cải thiện cơ chế ghi nhớ để hỗ trợ ghi nhớ dài hạn và cá nhân hóa sâu hơn. Bổ sung khả năng đa phương thức: cho phép người dùng tải lên hình ảnh bất động sản để chatbot phân tích và so sánh.

Về tìm kiếm, cần thử nghiệm các mô hình véc-tơ tiếng Việt chuyên biệt như PhoBERT để cải thiện chất lượng tìm kiếm ngữ nghĩa. Nghiên cứu áp dụng tìm kiếm lai kết hợp tìm kiếm toàn văn bản, tìm kiếm véc-tơ và tìm kiếm dựa trên đồ thị tri thức.

Về nền tảng, cần bổ sung các chức năng mới như so sánh bất động sản cạnh nhau, bản đồ nhiệt giá, biểu đồ xu hướng giá theo thời gian, cảnh báo giá khi có bất động sản phù hợp với tiêu chí người dùng, và xây dựng cộng đồng người dùng với tính năng bình luận và đánh giá.

Về triển khai, cần chuyển đổi từ Docker Compose sang Kubernetes để vận hành ở quy mô sản xuất với khả năng tự động mở rộng, cân bằng tải và phục hồi. Thiết lập đường ống tích hợp liên tục và triển khai liên tục để tự động hóa kiểm thử và phát hành. Bổ sung giám sát nâng cao với Grafana để trực quan hóa chỉ số hệ thống.

Về kiểm thử, cần tăng độ bao phủ kiểm thử, đặc biệt là kiểm thử đầu cuối cho các luồng nghiệp vụ chính. Xây dựng bộ kiểm thử hiệu năng để đảm bảo hệ thống đáp ứng được tải người dùng trong thực tế.

PHỤ LỤC

Phụ lục A CẤU TRÚC THƯ MỤC DỰ ÁN

Cấu trúc thư mục chính của dự án (rút gọn):

```
1 RealEstate_Chatbot_v2/└─
2   frontend/                                # Next.js 16 + React 19 + TypeScript└─
3     app/└─
4       page.tsx                            # Trang chủ└─
5       layout.tsx                          # Root layout└─
6       nha-dat-ban/                        # Danh sách & chi tiết BĐS bán└─
7         page.tsx└─
8         [id]/                             # Trang chi tiết (dynamic route)└─
9       nha-dat-cho-thue/                   # Danh sách & chi tiết cho thuê└─
10      thi-truong/                         # Dashboard tổng kê thị trường└─
11      admin/                             # Bảng điều khiển quản trị└─
12      dang-nhap/                          # Đăng nhập└─
13      dang-ky/                            # Đăng ký└─
14      components/└─
15        layout/                           # Header.tsx, Footer.tsx└─
16        listing/                          # ListingCard.tsx, ListingGrid.tsx└─
17        search/                           # FilterPanel.tsx└─
18        chatbot/                          # ChatWidget.tsx└─
19        admin/                             # AdminDashboard.tsx└─
20      lib/└─
21        api.ts                            # Typed API client (FastAPI)└─
22        types.ts                          # TypeScript interfaces└─
23        utils.ts                          # Format helpers└─
24        chatSourceDisplay.ts              # Chat source rendering└─
25      public/                             # Static assets└─
26
27      backend/                             # Backend API (FastAPI + SQLAlchemy)└─
28        app/└─
29          main.py                          # FastAPI app, CORS, router registration└─
30          config.py                       # Settings (env vars, defaults)└─
31          database.py                     # Async engine, session, Base└─
32          models/                         # 14+ ORM models└─
33            listing.py                    # - listings (30+ fields)└─
34            chunk.py                      # - chunks (pgvector 1024d)└─
35            chat.py                       # - chat_sessions, chat_messages└─
36            user.py                       # - users└─
37            project.py                    # - projects└─
38            article.py                    # - articles└─
39            pipeline_run.py               # - pipeline_runs└─
```

```

40     preference.py      #   - user_preferences,|||
41                       #   memory_proposals,|||
42                       #   chat_feedback|||└─
43     agent_observability.py # agent_traces,|||
44                       #   agent_trace_steps,|||
45                       #   agent_llm_calls,|||
46                       #   agent_retrieval_events|||└─
47     source_readiness.py  # source_readiness||└─
48     schemas/             # Pydantic v2 contracts|||└─
49     listing.py, chat.py, auth.py|||└─
50     common.py, admin.py, preferences.py||└─
51     routers/             # 7 router modules|||└─
52     listings.py          #   - /api/v1/listings|||└─
53     market.py           #   - /api/v1/market|||└─
54     chat.py             #   - /api/v1/chat|||└─
55     auth.py             #   - /api/v1/auth|||└─
56     preferences.py       #   - /api/v1/preferences|||└─
57     admin.py            #   - /api/v1/admin||└─
58     metrics.py          #   - /metrics||└─
59     services/||└─
60     chatbot/            # Pipeline multi-agent noi bo|||└─
61     router.py           #   Intent routing (keyword + Gemini)|||└─
62     orchestrator.py     #   Agent coordination|||└─
63     context.py          #   Conversation context|||└─
64     memory.py           #   User memory & preferences|||└─
65     contracts.py        #   RoutingDecision, AgentResult|||└─
66     analytics.py        #   Pipeline analytics||└─
67     agents/            #   4 specialist agents|||└─
68     property.py, market.py|||└─
69     legal.py, investment.py||└─
70     rag/               # RAG services|||└─
71     hybrid_search.py    #   SQL + pgvector + rerank + cache|||└─
72     embeddings.py       #   BGE-M3 embedder|||└─
73     simple_rag.py       #   Filter extraction|||└─
74     cache.py            #   Redis caching||└─
75     ingest.py           #   Vector store ingestion||└─
76     agent_service/     # Agent Service client||└─
77     client.py           #   HTTP client + internal key auth||└─
78     contracts.py        #   Request/response schemas|└─
79     tests/             # 58 test files||└─
80     conftest.py         #   Shared fixtures||└─
81     fixtures/          #   Test data||└─
82     test_*.py           #   Organized by module|└─
83     alembic/           #   DB migrations|└─
84     scripts/           #   Utility scripts|└─
85     requirements.txt|└─
86     Dockerfile|└─

```

```

87
88 agent_service/                                # Internal LangGraph Agent Service| |—
89     main.py                                    # FastAPI app (port 8100)| |—
90     config.py                                  # Agent-specific settings| |—
91     security.py                               # Internal key authentication| |—
92     contracts.py                              # AgentChatRequest/Response| |—
93     graph/| | |—
94         workflow.py                            # 8-node StateGraph| | |—
95         state.py                               # AgentGraphState| | |—
96         nodes.py                               # Node implementations| | |—
97         retrieval_planner.py                   # Multi-step retrieval planning| |—
98     agents/| | |—
99         specialists.py                         # 4 specialist agents| |—
100    tools/| | |—
101        retrieval.py                           # Hybrid search tool| | |—
102        market.py                             # Market stats tool| | |—
103        readiness.py                           # Data readiness check| |—
104    llm/| | |—
105        gemini.py                              # Gemini 2.0 Flash wrapper| |—
106    evaluation/| | |—
107        judge.py                               # LLM Judge (5 metrics)| |—
108    requirements.txt| |—
109    Dockerfile| |—
110
111    crawler/                                    # Playwright web scrapers| |—
112        core/                                  # Shared infrastructure| | |—
113            csv_writer.py                       # CSV with dedup| | |—
114            parser.py                           # Base parser| | |—
115            listing_detail_parser.py            # Full detail parser| |—
116    sale/                                       # Sale listings| | |—
117        crawl_urls.py                           # URL discovery (30 pages)| | |—
118        crawl_details.py                        # Detail scraping (4 workers)| |—
119    rent/                                       # Rental listings| | |—
120        crawl_urls.py| | |—
121        crawl_details.py| |—
122    projects/                                  # Real estate projects| | |—
123        crawl_urls.py| | |—
124        crawl_details.py| |—
125    news/                                       # News & articles| |—
126        crawl_articles.py| |—
127
128    data_pipeline/                             # ETL pipeline| |—
129        clean.py                                # Data cleaning & normalization| |—
130        enrich.py                               # Geocoding + intent tagging| |—
131        chunk.py                                # Semantic chunking (4 types)| |—
132        embed.py                                # BGE-M3 embedding (1024d, batch 16)| |—
133        load_db.py                             # PostgreSQL upsert| |—

```


```

134 ingestors/ # Source-specific ingestors||└─
135     listings_ingestor.py||└─
136     projects_ingestor.py||└─
137     news_ingestor.py||└─
138     legal_kb_ingestor.py|└─
139 legal/ # Legal KB processing|└─
140     chunker.py # Legal document chunking|└─
141     html_parser.py # HTML legal docs|└─
142     pdf_parser.py # PDF legal docs|└─
143     structure.py # Document structure|└─
144     manifest.py # Version tracking|└─
145     slug_disambiguation.py|└─
146
147 airflow/ # Workflow orchestration|└─
148     dags/ # 4 scheduled DAGs||└─
149         daily_listings_dag.py # Daily 02:00 HCM||└─
150         weekly_projects_dag.py # Sunday 03:00||└─
151         weekly_news_dag.py # Sunday 04:00||└─
152         monthly_legal_kb_dag.py # 1st day 05:00|└─
153     plugins/ # Airflow plugins||└─
154         pipeline_runner.py # Crawl & ingest runner||└─
155         alerting.py # Slack + email alerts||└─
156         run_metrics.py # Pipeline metrics|└─
157     Dockerfile|└─
158     requirements.txt|└─
159
160 chatbot/ # Legacy LangGraph sandbox|└─
161     graph.py, state.py, config.py|└─
162     agents/ # Experimental agents|└─
163     tools/ # Experimental tools|└─
164
165 docs/ # Documentation|└─
166     architecture.drawio # System architecture diagram|└─
167     implementation_plan.md|└─
168     multiagent-workflow.md|└─
169     pipeline.md|└─
170
171 report/ # LaTeX report|└─
172     main.tex|└─
173     preamble.tex|└─
174     contents/ # Chapter files|└─
175     figures/ # Architecture diagram (PNG)|└─
176
177 data/ # Data directory|└─
178     raw/ # Raw crawl output (CSV)|└─
179     knowledge/ # Legal KB source files|└─

```


Phụ lục B SƠ ĐỒ KIẾN TRÚC & LUỒNG DỮ LIỆU

Sơ đồ kiến trúc tổng thể



Hình 3.2: Sơ đồ kiến trúc tổng thể hệ thống (5 tầng: Người dùng – Frontend – Backend & Agent Service – Data – Pipeline)

Luồng dữ liệu từ Crawl đến Hiển thị

- Crawl (Playwright + Stealth):** Thu thập dữ liệu từ batdongsan.com.vn với 4 workers song song. Output: file CSV UTF-8 BOM, deduplicate theo product_id. Thực hiện bởi 4 module crawler (sale, rent, projects, news).
- Clean (data_pipeline/clean.py):** Chuẩn hóa dữ liệu thô – parse giá (“4,68 tỷ” → price=4.68, unit=billion), parse diện tích (“75 m²” → area=75), phân loại property_type, chuẩn hóa địa chỉ (tách ward, district, city).
- Enrich (data_pipeline/enrich.py):** Làm giàu dữ liệu với 2 tác vụ: (a) Geocoding –

gọi Nominatim/Goong API chuyển địa chỉ text → tọa độ (latitude, longitude); (b) Intent Tagging – phân tích mô tả, gán nhãn nhu cầu (“gần trường học”, “view đẹp”, “an ninh”, “pháp lý rõ”).

4. **Chunk (data_pipeline/chunk.py):** Chia mỗi listing thành 4 loại chunk ngữ nghĩa độc lập:
 - `overview` – Tổng quan: tiêu đề, giá, diện tích, khu vực, pháp lý, nội thất.
 - `description` – Mô tả chi tiết từ người đăng.
 - `location` – Vị trí: địa chỉ, quận/huyện, tỉnh/thành phố.
 - `intent_tags` – Nhu cầu phù hợp (dựa trên intent tagging).
5. **Embed (data_pipeline/embed.py):** Tạo vector embedding 1024 chiều cho từng chunk bằng BGE-M3 (BAAI/bge-m3). Sử dụng sentence-transformers với `batch_size=16`, `normalize=True`, retry 3 lần exponential backoff.
6. **Load DB (data_pipeline/load_db.py + ingestors/):** Upsert vào PostgreSQL qua asyncpg driver với batch processing (25–50 bản ghi/batch). Dữ liệu quan hệ → bảng listings; dữ liệu vector → bảng chunks với HNSW index (`m=16`, `ef_construction=64`).
7. **Serve (FastAPI + Next.js):** Backend API truy xuất dữ liệu qua hybrid search (SQL filtering + pgvector kNN + Cohere rerank + Redis cache). Frontend hiển thị qua Next.js App Router với SSR.
8. **Schedule (Apache Airflow):** Toàn bộ pipeline từ bước 1–6 được lập lịch tự động qua 4 DAGs (daily, weekly×2, monthly) với retry policy và alerting.

Luồng xử lý Chatbot

1. **User gửi query** qua ChatWidget (Frontend).
2. **Frontend gọi** `POST /api/v1/chat` (Backend).
3. **Backend xác thực** (JWT hoặc anonymous), kiểm tra quota, lưu ChatMessage.
4. **Router phân loại ý định** (keyword-based hoặc Gemini-based).
5. **Orchestrator chọn agents** và gọi song song qua `asyncio.gather()`.
6. **Agent thực thi** hybrid search (SQL + pgvector kNN ± Cohere rerank ± Redis cache).
7. **Kết quả tổng hợp** → AgentChatResponse (`final_response`, `sources`, `suggested_actions`).

8. **Nếu Agent Service được kích hoạt**, Backend ủy thác sang Agent Service (LangGraph 8-node workflow) thay vì pipeline nội bộ.
9. **Backend lưu** ChatMessage, AgentTrace và trả kết quả về Frontend.
10. **Frontend hiển thị** phản hồi kèm sources và suggested actions.

Phụ lục C DANH SÁCH API CHÍNH

Bảng 3.1 liệt kê các API endpoint chính của hệ thống (33 endpoints, 7 routers + metrics). Tất cả endpoint đều có tiền tố /api/v1 trừ /metrics và /api/v1/health.

Endpoint	Method	Mô tả
Listings		
GET /listings	GET	Danh sách BĐS (phân trang, 12+ bộ lọc: search, type, city, district, price, area, bedrooms,...)
GET /listings/{id}	GET	Chi tiết một BĐS (30+ trường)
GET /listings/by-product-id/{pid}	GET	Tìm BĐS theo product_id gốc từ nguồn crawl
GET /listings/similar/{id}	GET	BDS tương tự (cùng quận, loại hình, phân khúc giá)
Market		
GET /market/stats	GET	Tổng quan thị trường (tổng tin, giá TB, diện tích TB, số TP/quận)
GET /market/top-locations	GET	Top khu vực nhiều tin nhất (lọc theo listing_type)
GET /market/price-by-district	GET	Thống kê giá theo quận (avg, min, max, giá/m²)
GET /market/property-types	GET	Phân bố số lượng theo loại hình BĐS
GET /market/cities	GET	Danh sách thành phố + số lượng tin
GET /market/districts	GET	Danh sách quận/huyện (có thể lọc theo city)
GET /market/categories	GET	Danh sách tất cả loại hình BĐS
Chat		
POST /chat	POST	Gửi tin nhắn đến chatbot (tự động tạo session nếu chưa có)
GET /chat/sessions	GET	Danh sách phiên chat của user (cần xác thực)
GET /chat/sessions/{id}	GET	Lịch sử tin nhắn của một phiên chat
POST /chat/feedback	POST	Gửi đánh giá (rating, issue_type, comment)
Auth		
POST /auth/register	POST	Đăng ký tài khoản (email, password, full_name)
POST /auth/login	POST	Đăng nhập, nhận JWT token (hết hạn sau 24h)
GET /auth/me	GET	Thông tin người dùng hiện tại (cần xác thực)
Preferences & Memory		
GET/PATCH /preferences	GET/PATCH	Xem/cập nhật sở thích người dùng (cần xác thực)
POST /memory-proposals/{id}/accept	POST	Chấp nhận đề xuất ghi nhớ của chatbot
POST /memory-proposals/{id}/reject	POST	Từ chối đề xuất ghi nhớ
Admin (cần quyền admin)		
GET /admin/chat-traces	GET	Danh sách agent traces (intent, agents, latency)
GET /admin/chat-traces/{id}	GET	Chi tiết một trace (từng bước, input/output)
GET /admin/pipeline-readiness	GET	Trạng thái sẵn sàng của các nguồn dữ liệu

GET /admin/eval-runs	GET	Danh sách kết quả đánh giá LLM Judge
GET /admin/feedback	GET	Danh sách phản hồi người dùng về chatbot
GET /admin/memory-proposals	GET	Danh sách memory proposals đang chờ xử lý
GET /admin/agent-health	GET	Thống kê sức khỏe agent theo trạng thái
GET /admin/top-queries	GET	Top truy vấn phổ biến (đang phát triển)
System		
GET /api/v1/health	GET	Health check endpoint
GET /metrics	GET	Prometheus metrics (chat requests, latency, pipeline)

Bảng 3.1: Danh sách API endpoints chính của hệ thống (tiền tố mặc định: /api/v1)

Phụ lục D VÍ DỤ PHẢN HỒI CHATBOT

Ví dụ 1: Tìm kiếm bất động sản

User: “Tôi muốn mua căn hộ chung cư ở Quận 7, giá dưới 5 tỷ, 2 phòng ngủ”

Intent: property_search

Agent sử dụng: property_search

Bộ lọc trích xuất: {listing_type: "sale", property_type: "apartment", district: "Quận 7", max_price: 5, bedrooms: 2}

Phản hồi: Dựa trên yêu cầu của bạn, tôi tìm thấy một số căn hộ phù hợp tại Quận 7:

1. **Căn hộ chung cư ABC** – 4,2 tỷ, 72m², 2PN, 2WC, Phường Tân Phong. View sông, nội thất đầy đủ, pháp lý sổ hồng.
2. **Căn hộ Sunshine City** – 4,8 tỷ, 78m², 2PN, 1WC, Phường Phú Thuận. Gần trường học, an ninh tốt, có hồ bơi.
3. **Căn hộ Park View** – 3,9 tỷ, 68m², 2PN, 1WC, Phường Tân Quy. Giá tốt nhất khu vực, gần siêu thị.

Nguồn tham khảo: [Link BĐS 1] (độ liên quan: 0.95), [Link BĐS 2] (0.89), [Link BĐS 3] (0.82)

Gợi ý tiếp theo:

- “So sánh giá/m² các căn hộ này”
- “Thủ tục pháp lý khi mua chung cư cần những gì?”
- “Khu vực Quận 7 có tiềm năng tăng giá không?”

Ví dụ 2: Tư vấn pháp lý + thị trường

User: “Thủ tục sang tên sổ đỏ mất bao lâu? Với lại giá đất ở Quận 9 hiện nay thế nào?”

Intent: mixed (legal_advice + market_analysis)

Agent sử dụng: legal_advisor, market_analysis

Phản hồi: Tôi sẽ giải đáp từng phần câu hỏi của bạn:

1. Thủ tục sang tên sổ đỏ:

Theo quy định hiện hành, thủ tục sang tên sổ đỏ (chuyển nhượng quyền sử dụng đất) gồm các bước chính:

- Công chứng hợp đồng chuyển nhượng tại văn phòng công chứng (1–2 ngày).
- Khai thuế thu nhập cá nhân và lệ phí trước bạ tại Chi cục Thuế (3–5 ngày).
- Nộp hồ sơ sang tên tại Văn phòng Đăng ký Đất đai (10–15 ngày làm việc).

Tổng thời gian ước tính: **3–5 tuần** tùy địa phương.

Lưu ý quan trọng: Cần kiểm tra đất không có tranh chấp, không bị quy hoạch, và đã hoàn thành nghĩa vụ tài chính.

2. Giá đất tại Quận 9:

Hiện tại (dữ liệu cập nhật từ hệ thống):

- Giá đất nền trung bình: **35–55 triệu/m²** tùy vị trí.
- Giá đất mặt tiền đường lớn: **60–90 triệu/m²**.
- Xu hướng: tăng nhẹ 5–8% so với cùng kỳ năm trước, được thúc đẩy bởi hạ tầng giao thông (Metro, Vành đai 3).

Nguồn tham khảo: [Link KB Pháp lý 1], [Link KB Pháp lý 2], [Link Thống kê Quận 9]

Gợi ý tiếp theo:

- “Các loại thuế phí khi mua đất là gì?”
- “So sánh giá đất Quận 9 với Quận 2 và Thủ Đức”
- “Có nên đầu tư đất nền Quận 9 thời điểm này?”

CHỈ MỤC

TÀI LIỆU THAM KHẢO